



**ArtAdvisor: Proiectarea unui Asistent Conversațional
pentru Interpretarea Multi-Modală și Narativă a Artei**

— O Arhitectură Bazată pe Ansambluri de Deep Learning, Generare
de Limbaj și Sinteză Vocală —

LUCRARE DE LICENȚĂ

Absolvent: **Dan Lucian GHILEA**

Coordonator **As. dr. ing. Cristina Maria FEIER**
științific:



FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE
DEPARTAMENTUL CALCULATOARE

DECAN,
Prof. dr. ing. Vlad MUREŞAN

DIRECTOR DEPARTAMENT,
Prof. dr. ing. Rodica POTOLEA

Absolvent: **Dan Lucian GHILEA**

ArtAdvisor: Proiectarea unui Asistent Conversațional pentru Interpretarea Multi-Modală și Narativă a Artei

— O Arhitectură Bazată pe Ansambluri de Deep Learning, Generare de Limbaj și Sinteză Vocală —

1. **Enunțul temei:** Scurtă descriere a temei lucrării de licență și datele inițiale
2. **Conținutul lucrării:** (enumerarea părților componente) *Exemplu: Pagina de prezentare, aprecierile coordonatorului de lucrare, titlul capitolului 1, titlul capitolului 2, titlul capitolului n, bibliografie, anexe.*
3. **Locul documentării:** *Exemplu: Universitatea Tehnică din Cluj-Napoca, Departamentul Calculatoare*
4. **Consultanți:**
5. **Data emiterii temei:** 1 Noiembrie 2024
6. **Data predării:** 11 Septembrie 2025

Absolvent: _____

Coordonator științific: _____



FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE
DEPARTAMENTUL CALCULATOARE

**Declarație pe propria răspundere privind
autenticitatea lucrării de licență**

Subsemnatul(a) _____, legitimat(ă) cu
_____ seria _____ nr. _____
CNP _____, autorul lucrării

elaborată în vederea susținerii examenului de finalizare a studiilor de licență la Facultatea de Automatică și Calculatoare, Specializarea _____ din cadrul Universității Tehnice din Cluj-Napoca, sesiunea _____ a anului universitar _____, declar pe propria răspundere că această lucrare este rezultatul propriei activități intelectuale, pe baza cercetărilor mele și pe baza informațiilor obținute din surse care au fost citate, în textul lucrării și în bibliografie.

Declar că această lucrare nu conține porțiuni plagiate, iar sursele bibliografice au fost folosite cu respectarea legislației române și a convențiilor internaționale privind drepturile de autor.

Declar, de asemenea, că această lucrare nu a mai fost prezentată în fața unei alte comisii de examen de licență.

În cazul constatării ulterioare a unor declarații false, voi suporta sancțiunile administrative, respectiv, *anularea examenului de licență*.

Data

Nume, Prenume

Semnătura

Instructiuni generale.

De citit înainte (această pagină se va elimina din versiunea finală):

1. Cele trei pagini anterioare (foaie de capăt, foaie sumar, declarație) se vor lista pe foi separate (nu față-verso), fiind incluse în lucrarea listată. Foaia de sumar (a doua) necesită semnătura absolventului, respectiv a coordonatorului. Pe declarație se trece data când se predă lucrarea la secretarii de comisie.
2. Pe foaia de capăt, se va trece corect titulatura cadrului didactic îndrumător, în engleză (consultați pagina de unde ati descărcat acest document pentru lista cadrelor didactice cu titulaturile lor).
3. Fiecare capitol începe pe pagină nouă.
4. Marginile paginilor nu se modifică.
5. Respectați restul instrucțiunilor din fiecare capitol.
6. Am inclus pachetul `hyperref` pentru a genera legături de navigare atât în document cât și la link-uri de web. Pentru listarea pe hârtie a fișierului pdf decommentați linia care conține `\hypersetup{hidelinks}` aflată în partea de început a fișierului principal `thesis_rom.tex`.

Cuprins

Capitolul 1. Introducere

1.1. Contextul proiectului

Arta picturală a fost dintotdeauna un mediu privilegiat de exprimare a emoțiilor. Prin culoare, lumină, compoziție și textură, artiștii transmit stări nuanțate, adesea simultane, care solicită din partea publicului atât sensibilitate estetică, cât și un minim repertoriu interpretativ. În era accesului digital la patrimoniu, „a vedea” nu înseamnă automat „a înțelege”: utilizatorul ajunge ușor la imagine, dar rămâne adesea fără repere afective explicite.

În acest context, proiectele de mediere culturală pot beneficia de contribuția interdisciplinară a informaticii și științelor cognitive. Inteligența artificială aplicată imaginilor, psihologia afectului și designul centrat pe utilizator converg către instrumente capabile să conecteze percepția cu interpretarea. O prezentare afectivă clară, sobră și accesibilă are valoare educațională pentru publicul larg, valoare curatorială pentru organizarea conținutului în medii digitale și valoare de cercetare pentru testarea ipotezelor despre relația dintre indicii vizuali și trăirile asociate.

Proiectul ArtAdvisor se înscrie în această zonă de intersecție dintre știința datelor vizuale și studiile umaniste, vizând construirea unei punți între imagine și înțelegerea afectivă pe care o poate genera. Accentul cade pe calitatea comunicării către utilizator și pe caracterul explicabil al rezultatului, astfel încât experiența să fie utilă atât în contexte educaționale, cât și în explorarea individuală a colecțiilor.

1.2. Motivație și impact

Necesitatea unei punți între percepția vizuală și interpretarea afectivă rezultă din trei observații: (i) publicul larg are acces facil la imagini, dar dificil la sensurile lor afective; (ii) curatorii și educatorii caută instrumente standardizate pentru a comunica nuanțe emotionale în medii digitale; (iii) cercetarea computațională a afectului în artă oferă astăzi cadre teoretice și date relevante, dar are nevoie de formate de prezentare pe înțelesul publicului.

Din această perspectivă, ArtAdvisor contribuie în mod pragmatic la medierea culturală: transformă scoruri abstractive în rezultate lizibile, utile și verificabile, orientate spre utilitatea educațională și cercetare aplicată.

1.3. Formularea problemei

Emoția artistică este adesea polifonică: aceeași lucrare poate îmbina calmul cu misterul, melancolia cu speranța sau tensiunea cu uimirea. În pictură, astfel de efecte apar din interacția factorilor locali (tușă, contur, textură) cu factorii globali (echilibru compozitional, direcții dominante, raporturi cromatice).

Problema practică vizată este trecerea de la percepție la interpretare afectivă în era digitală, oferind publicului indicii lizibile despre emoțiile pe care o imagine le poate comunica, fără a presupune expertiză de specialitate. Aceasta se formulează ca o problemă de clasificare multi-etichetă, unde o singură imagine poate exprima simultan mai multe

emoții relevante.

1.4. Delimitarea domeniului

Tema acestei lucrări este formulată ca problemă de recunoaștere și comunicare a emoțiilor în pictură din perspectivă computațională. Pentru fiecare imagine de operă picturală se construiește un profil emoțional care surprinde co-prezența mai multor emoții relevante, iar rezultatul este prezentat într-o formă lizibilă și prietenoasă publicului nespecialist.

1.4.1. Delimitări și clarificări

- **Domeniul vizat:** pictură (imagini statice). Nu sunt abordate audio, video sau alte forme artistice.
- **Formularea:** multi-etichetă - o lucrare poate exprima simultan mai multe emoții; rezultatul urmărit este un profil emoțional interpretabil pentru utilizator.
- **Obiectivul:** sprijinul în înțelegerea afectivă și comunicarea rezultatelor într-un mod accesibil și explicabil.
- **Limitări:** nu intră în sfera judecății estetice normative sau a evaluărilor valorice asupra operelor.

1.4.2. Formular operațională

- **Intrare:** imagine RGB a unei picturi
- **Ieșire:** vector de scoruri pe 14 emoții și subsetul emoțiilor dominante
- **Cadru decizional:** clasificare multi-etichetă cu praguri adaptive per emoție
- **Evaluare:** F1-Macro, Average Precision (AP) și curbe Precision-Recall

1.5. Public-țintă și scenarii de utilizare

Soluția se adresează atât publicului larg, cât și profesioniștilor implicați în medierea culturală în mediul digital:

- **Vizitator digital:** înțelege rapid profilul emoțional al unei lucrări printr-o prezentare prietenoasă și explicabilă
- **Curator/educator:** folosește profilul emoțional pentru a organiza colecții online sau a crea parcursuri tematice centrate pe trăiri
- **Cercetător aplicat:** validează ipoteze privind relația dintre indicii vizuali și percepția afectivă

1.6. Criterii de succes

Pentru a evalua utilitatea în contextul propus, adopt următoarele criterii concepțuale:

- **Lizibilitate:** rezultatul este ușor de înțeles de către publicul nespecialist
- **Explicabilitate:** există trasabilitate între scorurile pe emoții și decizia finală
- **Coerentă metodologică:** terminologia și modul de raportare rămân constante
- **Interoperabilitate:** formatul de ieșire este ușor de integrat în interfețe digitale

1.7. Delimitarea contribuțiilor

În cadrul proiectului colaborativ ArtAdvisor, contribuțiile sunt delimitate astfel:

Contribuția autorului (Lucian Ghilea): modelarea teoretică și implementarea modelului de recunoaștere a emoțiilor din imagini de artă, formularea problemei multi-etichetă pentru emoții, dezvoltarea profilului emoțional interpretabil, crearea interfeței interactive Streamlit cu tab-uri dedicate (Galerie, Verificare, Chat Artist, Laborator Emoțional), integrarea funcționalității text-to-speech pentru accesibilitate îmbunătățită, vizualizări interactive pentru validarea academică și mecanisme de semnare emoțională a rezultatelor.

Contribuția colegului (David Iakabos): clasificarea stilurilor artistice și identificarea autorilor, implementarea Grad-CAM îmbunătățit pentru explicabilitate vizuală, generarea interpretărilor narrative prin servicii AI externe, dezvoltarea arhitecturii modulare și scalabile a sistemului, crearea sistemului de generare rapoarte HTML, implementarea chat-ului interactiv cu expert artificial și dezvoltarea sistemului de colectare feedback utilizator.

Colaborarea s-a concentrat pe integrarea componentelor într-o arhitectură coerentă, optimizarea fluxului aplicației și asigurarea unei experiențe utilizator intuitive și explicabile. Prezenta lucrare se focalizează pe contribuția autorului în domeniul recunoașterii emoțiilor, menționând contextual elementele colaborative necesare pentru înțelegerea sistemului integrat.

1.8. Vocabular emoțional

Vocabularul utilizat cuprinde 14 emoții din taxonomia lui Plutchik, adaptat pentru analiza artei: Sadness, Trust, Fear, Disgust, Anger, Anticipation, Happiness, Love, Surprise, Optimism, Gratitude, Pessimism, Regret, Agreeableness.

1.9. Structura lucrării

Lucrarea este organizată în opt capitole:

- **Capitolul 1** — Introducere: context, motivație, domeniu și delimitări
- **Capitolul 2** — Obiectivele proiectului: formulare de proiectare și obiective măsurabile
- **Capitolul 3** — Studiu bibliografic: stadiul domeniului și corpusuri de referință
- **Capitolul 4** — Analiză și fundamentare teoretică: principii funcționale și modele abstrakte
- **Capitolul 5** — Proiectare de detaliu și implementare: schema aplicației și modulele principale
- **Capitolul 6** — Testare și validare: protocol, metriki și rezultate
- **Capitolul 7** — Manual de instalare și utilizare: ghid practic de folosire
- **Capitolul 8** — Concluzii: sinteză și direcții viitoare

Capitolul 2. Obiectivele proiectului

2.1. Formularea temei

Tema propusă: Dezvoltarea unei platforme computaționale pentru recunoașterea emoțiilor în opere de artă folosind *inteligenta artificială*. Platforma va permite analiza picturilor și identificarea emoțiilor pe care le transmit, oferind utilizatorilor o experiență interactivă și educativă în înțelegerea artei digitale.

Proiectul vizează **îmbinarea tehnologiei moderne cu aprecierea artistică**, facilitând accesul publicului larg la interpretarea și înțelegerea operelor de artă prin intermediul tehnologiei.

Soluția propusă oferă:

- *Analiză emoțională completă* - identificarea și evaluarea emoțiilor transmise de fiecare operă de artă
- *Prezentare accesibilă* - rezultate prezentate în mod vizual și narativ pentru înțelegere facilă
- *Instrumente de validare* - mecanisme pentru verificarea și testarea robustetii analizelor efectuate

2.2. Obiectiv general

Obiectivul principal al acestui proiect constă în realizarea unei platforme *ArtAdvisor* care să permită *analiza emoțională* a operelor de artă într-o manieră **accesibilă și precisă**.

Platforma va combina *rigoarea științifică* cu *claritatea prezentării*, oferind utilizatorilor posibilitatea să înțeleagă și să aprecieze operele de artă din perspectiva emoțională pe care acestea o transmit.

Prin intermediul platformei ArtAdvisor, utilizatorii vor avea acces la:

- *Analiză emoțională precisă* și comprehensivă
- *Explicații clare* și ușor de înțeles
- *Instrumente de validare* pentru verificarea rezultatelor

2.3. Obiective specifice

2.3.1. Analiza și interpretarea emoțiilor

- **Identificarea emoțiilor** - recunoașterea unui set de 14 emoții distințe în operele de artă
- **Evaluarea intensității** - determinarea gradului de expresivitate pentru fiecare emoție identificată

2.3.2. Dezvoltarea modelului de recunoaștere

- **Arhitectura sistemului** - crearea unui model capabil să analizeze *caracteristicile locale și globale* ale imaginilor
- **Calibrarea deciziilor** - stabilirea unor *criterii adaptive* pentru identificarea corectă a emoțiilor dominante

2.3.3. Validarea și testarea sistemului

- **Protocole de testare** - implementarea unor metode comprehensive de evaluare a performanței
- **Testarea robustetii** - verificarea stabilității sistemului în condițiile modificărilor *foto-realiste*
- **Prezentarea rezultatelor** - dezvoltarea unor modalități *clare și intuitive* de comunicare a analizelor

2.3.4. Interfața și experiența utilizatorului

- **Organizarea funcționalităților** - structurarea platformei în *module distincte* pentru diferite tipuri de analize
- **Accesibilitatea** - asigurarea unor opțiuni *diverse de prezentare* a rezultatelor (vizual, audio, export)

2.3.5. Cerințe funcționale

Platforma ArtAdvisor trebuie să îndeplinească următoarele funcționalități:

- **Analiza emoțională** - *identificarea și evaluarea* emoțiilor din opere de artă cu posibilitatea detectării *multiple emoții simultane*
- **Generarea profilurilor emoționale** - crearea unei *reprezentări complete* a impactului emoțional al fiecărei opere
- **Explicarea rezultatelor** - oferirea de *justificări vizuale* pentru deciziile sistemului privind emoțiile identificate
- **Narătivă automată** - generarea de *descrieri textuale* comprehensive ale analizelor efectuate
- **Verificarea autenticității** - implementarea unui sistem de *semnătură digitală* pentru validarea operelor analizate
- **Organizarea rezultatelor** - dezvoltarea unei *galerii interactive* cu opțiuni de filtrare după criterii multiple

2.3.6. Cerințe non-funcționale

Sistemul trebuie să respecte următoarele criterii de calitate:

- **Performanță** - *timpul de analiză* pentru o imagine să nu depășească 15 secunde după inițializarea sistemului
- **Reproductibilitate** - *rezultatele analizelor* să fie constante și predictibile pentru aceeași operă de artă
- **Robustete** - sistemul să mențină *stabilitatea performanței* chiar și în condițiile modificărilor minore ale imaginii
- **Securitate și integritate** - implementarea unui sistem de *protectie* care să nu afecteze vizual opera originală
- **Accesibilitate** - interfața să fie *intuitivă și ușor de utilizat*, cu opțiuni diverse de prezentare a rezultatelor
- **Transparentă** - sistemul să ofere *informații clare* despre metodele de analiză și gradul de certitudine al rezultatelor

2.4. Criterii de reușită

2.4.1. Calitatea analizei emoționale

- **Precizia identificării** - sistemul să atingă o *performanță satisfăcătoare* în recunoașterea corectă a emoțiilor
- **Echilibrul în detectare** - capacitatea de *identificare echitabilă* a tuturor tipurilor de emoții analizate

2.4.2. Experiența utilizatorului

- **Răspuns rapid** - analiza unei opere să se finalizeze în *maximum 15 secunde*
- **Interacțiune fluidă** - interfața să devină *funcțională* în maximum 10 secunde de la pornire

2.4.3. Completitudinea livrabilelor

- **Vizualizări comprehensive** - toate analizele să genereze *reprezentări grafice și tabele explicative*
- **Flexibilitate în prezentare** - disponibilitatea *opțiunilor de export și a narațiunilor descriptive* pentru fiecare analiză

2.5. Figuri explicative

Prin **????** sunt indicate locuri pentru două figuri de sinteză; acestea vor fi complete în capitolele tehnice, cu imagini exportate din pipeline-ul de validare și schema de sistem.

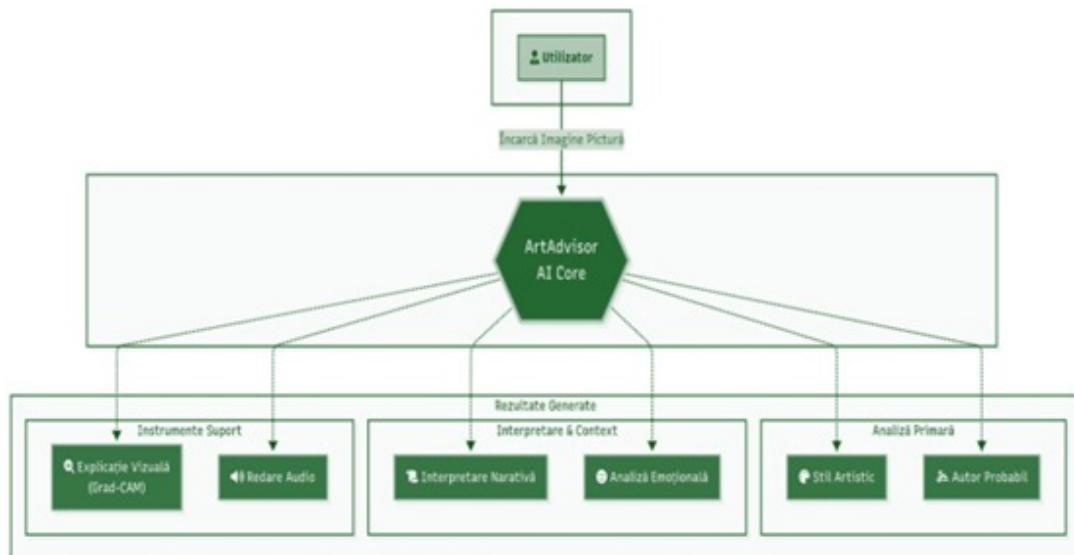


Figura 2.1: Obiective și funcționalități principale: intrare → profil emoțional multi-etichetă (cu praguri adaptive) → ieșiri și prezentare.

Placeholder flux validare / evaluare
(va fi înlocuit cu exportul final din pipeline)

Etape: Input imagini → Preprocesare → Model ansamblu → Scoruri emoții → Praguri adaptive → Metrici (F1, AP) → Raport

Figura 2.2: Flux conceptual de validare și evaluare: traseul datelor de la imagine brută la metrici sintetice.

2.6. Sinteză

Obiectivele proiectului sunt *clare și măsurabile*, vizând dezvoltarea unei platforme complete pentru analiza emoțională a operelor de artă. Prin combinarea *preciziei tehnice* cu *accesibilitatea pentru utilizatori*, platforma ArtAdvisor își propune să democratizeze înțelegerea și aprecierea artei.

Capitolul de față trasează **cadrul conceptual** și criteriile de realizare. Fundamentele teoretice, proiectarea și implementarea sistemului, precum și testarea și validarea vor fi detaliate în capitolele următoare, demonstrând atingerea obiectivelor propuse și *utilitatea practică* a soluției dezvoltate.

Capitolul 3. Studiu bibliografic

3.1. Context și justificare

Interpretarea *emoțiilor* comunicate de arta picturală a atras, în ultimele decenii, interesul convergent al psihologiei afective, neuroesteticii și viziunii computaționale. Cercetarea neuro-cognitivă a reliefat legături consistente între *percepția vizuală* și *răspunsul emoțional* la stimuli artistic [?], în timp ce progresele în *învățarea profundă* au făcut posibilă modelarea regularităților subtile din imagini, dincolo de reguli explicite. În acest cadru, tema recunoașterii emoțiilor în picturi are o dublă motivație:

- **Științifică:** testarea capacitatei modelelor moderne de a opera într-un spațiu semantic nuanțat, cu *co-ocurențe* și *ambiguități* inerente;
- **Cultural-educațională:** facilitarea unei *medieri interpretative* accesibile, care să apropie publicul de dimensiunea afectivă a patrimoniului vizual.

Exemplu aplicat. Într-un tablou romantic, cromatica caldă și compoziția deschisă pot induce simultan *Optimism, Încredere și Iubire*; o clasificare *multi-etichetă* captează această co-prezență mai bine decât o formulare mono-etichetă.

3.2. Fundamente psihologice ale emoției în artă

3.2.1. Modele canonice ale expresiei afective

Literatura de specialitate oferă câteva repere stabile:

- **Emoții universale** (Ekman) — un set restrâns de stări afective de bază, observabile intercultural [?];
- **Circumplexul afectiv** (Russell) — reprezentarea emoțiilor în planul *valență-arousal* [?], cu susțineri neuroimagistice ulterioare [?];
- **Roata emoțiilor** (Plutchik) — relații între emoții *primare* și *compuse*, utile pentru descrieri fine [?];
- **Appraisal** (Scherer) — emoția ca rezultat al evaluărilor succesive ale stimulilor [?].

Aceste cadre justifică atât *formulări categoriale* (clase discrete), cât și *abordări dimensionale* (scoruri continue) ale afectului.

Implicație metodologică. Pentru un sistem care produce scoruri per emoție, calibrarea deciziilor (praguri) devine analogă unei *proiecții* din spațiul continuu (valență/arousal sau scoruri sigmoide) în spațiul deciziilor binare, specific interfeței.

3.2.2. Particularități ale picturii clasice

În pictură, *culoarea, compoziția, lumina și textura* funcționează ca vectori afectivi. Kandinsky a explorat potențialul emoțional al culorii [?]; Arnheim a clarificat rolul structurilor gestaltiste [?]; Berlyne a legat proprietăți perceptive (noutate, complexitate) de preferință estetică [?]. Dimensiunea **culturală** a interpretării rămâne esențială [?, ?], motiv pentru care standardizarea etichetelor cere prudență.

Exemplu aplicat. Tonurile reci și contrastul ridicat pot corespunde *Frică*/*Tristețe* într-un context cultural, dar *Serenitate* într-altul; seturile de date trebuie să surprindă diversitatea contextelor.

3.3. Corpusuri și resurse pentru analiza afectivă

Progresul aplicat depinde de corpusuri *curate* și *coherent adnotate*. Direcții relevante:

- **Affective image analysis în artă:** trăsături inspirate din psihologia artei (culoare, compoziție, textură) [?, ?];
- **Multimodalitate cu explicații text:** *ArtEmis* combină etichete emoționale cu descrieri narrative, sporind *explicabilitatea* [?].

Provocări recurente:

- *Variabilitatea inter-evaluator*: acord mai scăzut decât în recunoașterea expresiilor faciale;
- *Dezechilibrul de clasă*: emoții rare sub-reprezentate.

Soluții practice (extrase din literatura de ML aplicată):

- *Curățare semantică* și deduplicare; split-uri stratificate menținând co-ocurențe;
- *Eșantionare ponderată* și *pierderi ponderate* (ex. *pos_weight* în BCE) pentru clase rare [?];
- Augmentări *fotorealistice*, conservând semnificația cromatică/compusă a operei.

3.3.1. Vizualizări ilustrative ale corpusurilor (grupate pe categorii)

Pentru a ancora discuția despre seturile de date folosite în cercetarea afectului în artă, grupez vizualizările în trei categorii: (A) **WikiArt Emotions — statistici și sursă de etichete**, (B) **ArtEmis — distribuții și co-ocurențe**, (C) **ArtEmis — exemple calitative textuale**. Aceste figuri nu sunt produse de sistemul implementat; ele oferă context și motivează alegerile metodologice din cap. 4–5 (praguri per emoție, metrii echitabile, sampling).

(A) **WikiArt Emotions — statistici și sursă**

(B) **ArtEmis — distribuții și co-ocurențe**

(C) **ArtEmis — exemple calitative (explicații text)**

3.4. Metode computaționale moderne pentru analiză vizuală

3.4.1. Arhitecturi convoluționale și eficiență

De la **AlexNet** [?] la **VGG** [?] și **ResNet** [?], CNN-urile au stabilit standardul, captând *indicii locale* esențiale (tușe, margini, texturi). **EfficientNet** optimizează scalarea compusă pentru un compromis superior acuratețe-cost [?].

3.4.2. Transformere vizuale și atenție globală

Vision Transformer (ViT) introduce *atenția* în analiză vizuală, facilitând surprinderea *contextului global* și a relațiilor compozitionale [?]. Variante ierarhice (ex. **Swin**)

Art Style	Art Category	Agree..	Anger	Antici..	Arroga..	Disagr..	Disgust	Fear	Gratitu..	Happi..	Humili..	Love	Optimi..	Pessi..	Regret	Sadne..	Shame	Shyne..	Surpri..	Trust	Neutral
Contemporary Art	Minimalism	1.19	-0.22	0.43	0.23	-0.24	-0.76	-0.18	1.50	1.65	0.48	1.30	1.07	-0.34	0.41	-0.15	-0.54	-0.13	-0.06	1.52	-0.66
	Abstract Art	1.62	-0.22	0.61	0.52	0.15	-0.70	-0.23	1.74	1.65	1.14	1.91	1.33	-0.26	0.23	-0.03	0.02	0.81	0.28	1.54	-0.21
	Abstract Expressionism	1.46	0.21	0.64	0.75	0.04	-0.79	-0.22	1.88	1.55	0.92	1.70	1.36	0.05	0.85	0.33	0.08	0.71	0.28	1.62	-0.41
	Art Informel	1.70	-0.30	0.56	0.16	-0.08	-0.75	-0.34	1.84	1.55	0.84	1.50	1.34	-0.35	0.00	0.22	-0.40	0.40	0.13	1.46	-0.32
	Color Field Painting	1.19	-0.52	0.48	0.33	-0.34	-0.88	-0.67	1.44	1.53	0.77	1.51	1.27	-0.59	0.31	-0.13	-1.17	0.03	0.08	1.61	-0.47
	Cubism	1.86	0.34	0.93	0.55	0.52	-0.26	0.31	1.60	1.61	1.32	1.80	1.55	0.25	0.68	0.68	0.25	0.94	0.52	1.65	-0.23
	Expressionism	1.34	0.67	1.20	0.65	1.10	-0.14	0.31	1.84	1.61	1.56	1.81	1.71	0.69	1.03	0.70	0.40	1.00	0.82	1.67	0.00
	Impressionism	1.76	1.51	1.69	1.16	1.66	0.82	1.09	1.94	1.99	1.96	2.15	2.15	1.01	1.48	1.20	1.01	1.57	1.61	1.96	1.20
	Lyrical Abstraction	1.38	0.18	0.85	1.08	0.44	-0.76	-0.14	1.98	1.75	1.26	1.78	1.51	0.18	0.66	0.33	0.83	0.85	0.39	1.82	-0.44
	Magic Realism	1.92	0.92	1.44	1.20	1.05	-0.16	0.67	2.01	1.92	1.74	2.07	2.04	0.74	1.50	1.04	0.59	1.65	1.15	1.95	0.30
Post Renaissance Art	Neo-Expressio..	1.54	-0.22	0.86	0.13	0.04	-0.70	-0.27	1.43	1.60	1.09	1.77	1.39	0.11	0.30	0.42	-0.01	0.86	0.45	1.59	-0.59
	Pop Art	1.34	0.19	0.79	0.32	0.52	-0.54	0.07	1.62	1.59	1.07	1.62	1.39	0.31	0.56	0.50	0.01	0.68	0.34	1.43	-0.82
	Post-Impressi..	1.56	1.04	1.40	0.93	1.54	0.59	0.53	1.94	1.84	1.71	2.01	1.90	0.78	1.14	1.09	0.87	1.49	1.19	1.82	-0.13
	Surrealism	1.54	-0.09	0.98	0.43	0.10	-0.78	-0.21	1.74	1.86	1.33	1.86	1.52	0.13	0.45	0.50	0.08	0.37	0.41	1.71	-0.48
	Baroque	1.71	1.26	1.68	1.02	1.35	0.78	1.01	1.92	1.77	1.84	2.03	1.81	1.05	1.41	1.15	0.93	1.89	1.57	1.80	-1.00
	Neoclassicism	1.91	1.13	1.80	1.08	1.59	0.85	1.10	2.09	1.94	2.04	2.16	1.97	1.28	1.52	1.21	1.12	1.69	1.77	1.84	0.50
	Realism	1.77	0.64	1.67	1.14	1.53	0.63	0.96	2.09	1.93	1.88	2.12	2.03	0.94	1.34	1.28	1.16	1.79	1.59	1.92	0.88
Renaissance Art	Rococo	1.79	0.87	1.60	1.01	1.14	0.52	0.84	2.02	1.96	1.90	2.10	1.99	0.99	1.44	1.17	1.06	1.88	1.52	1.82	0.00
	Romanticism	1.73	1.02	1.71	1.23	1.16	0.70	1.01	2.08	1.88	1.89	2.20	1.99	0.94	1.31	1.24	0.88	1.70	1.57	1.82	0.50
	Early Renaissance	1.56	0.67	1.41	0.63	1.01	0.28	0.65	1.70	1.62	1.63	1.81	1.61	0.73	0.82	0.69	0.42	1.26	1.64	1.65	0.00
	High Renaissance	1.52	1.07	1.69	1.11	1.48	0.21	0.81	1.87	1.81	1.88	1.99	1.94	0.95	1.24	1.02	0.31	1.45	1.54	1.84	2.00
Northern Renaissance	Northern Renaissance	1.40	0.62	1.31	0.71	0.76	0.01	0.70	1.75	1.67	1.69	1.81	1.75	0.61	0.84	0.90	0.61	1.56	1.47	1.66	0.22

Figura 3.1: Variația rating-urilor medii pe perechi *categorie artistică–emoție* (WikiArt Emotions). Valorile (-3..3) oferă context de *valență* pe categorii.

cresc eficiența [?]. *Attention is All You Need* [?] fundamentează cadrul; în sarcini complexe, **DETR** sugerează formulări end-to-end [?]. Pentru pictură, *fuziunea local–globală* (CNN + Transformer) e naturală: *detaliul pictural* și *compoziția* se susțin reciproc.

Exemplu aplicat. Un ansamblu EfficientNet–B2 (detalii locale) + ViT–B/16 (relații globale) oferă complementaritate inductivă: pensulația și texturile susțin semnalele cromatice, iar atenția pe patch-uri captează coerentă compozitională.

3.5. Clasificare multi–etichetă și decizie calibrată

Emoțiile pot *coexista* în aceeași operă; prin urmare, formularea firească este **multi–etichetă** [?]. Strategiile includ transformări ale problemei (One–vs–All) versus modele native [?]. În practică:

- **BCEWithLogitsLoss** — stabilitate numerică pentru scoruri independente;
- **Focal Loss** — utilă pentru clase rare și exemple dificile [?];
- **Praguri adaptive per clasă** — optimizate pe validare, controlează explicit *precizia–rechemare*.

Soluție concretă (decizie). Se scaneză un grid de praguri (ex. 0.10–0.90) pentru fiecare emoție; se reține pragul care maximizează F1 pe validare — o metodă simplă, robustă și reproductibilă pentru seturi dezechilibrate.

3.6. Dezechilibre de clasă, regularizare și optimizare

3.6.1. Dezechilibru: efecte și remedii

Dezechilibrele afective cer *eșantionare/ponderare* atentă și augmentări cu grijă la *semnificația estetică*. Analize sistematice sunt oferite de [?]. În plus față de *pos_weight*:

- **WeightedRandomSampler** — expune mai des exemple din clasele rare;

Style	Category	Agree..	Anger	Antici..	Arroga..	Disagr..	Disgust	Fear	Gratitu..	Happi..	Humili..	Love	Optimi..	Pessi..	Regret	Sadne..	Shame	Shyne..	Surpri..	Trust	Neutral
<i>Contemporary Art</i>	Minimalism	-0.01	0.01	0.00	0.01	-0.01	-0.02	0.07	-0.01	0.02	0.00	0.08	0.01	0.01	-0.01	0.07	0.01	0.01	-0.01	0.01	-0.01
<i>Modern Art</i>	Abstract Art	0.01	0.04	0.01	-0.02	0.00	0.01	0.08	0.00	0.09	0.00	0.00	0.01	0.01	-0.01	0.02	0.04	-0.01	0.00	-0.01	0.00
	Abstract Expressionism	0.01	0.02	0.02	-0.02	-0.02	0.02	0.10	-0.01	0.06	0.03	0.03	0.04	0.02	0.00	0.04	0.00	-0.01	0.01	-0.01	0.00
	Art Informel	0.00	0.03	0.00	-0.01	0.00	-0.01	0.07	-0.01	0.07	-0.02	0.03	0.03	0.04	0.00	0.03	0.01	0.00	-0.01	-0.01	0.00
	Color Field Painting	0.01	0.02	-0.01	-0.01	0.00	0.00	0.03	0.02	0.07	0.00	0.00	0.02	0.04	-0.02	0.07	0.03	0.00	0.01	0.00	0.00
	Cubism	-0.01	0.03	0.02	0.06	0.01	0.01	0.11	0.00	0.11	0.05	0.11	0.01	0.04	0.03	0.09	0.07	0.01	0.07	0.05	0.02
	Expressionism	0.00	0.04	0.00	0.04	-0.01	0.04	0.20	0.03	0.18	0.06	0.18	0.03	0.10	0.07	0.22	0.06	0.02	0.01	0.04	0.00
	Impressionism	0.00	0.08	-0.01	0.06	0.00	0.02	0.16	0.02	0.21	0.01	0.19	0.03	0.06	0.00	0.19	0.02	-0.01	-0.02	0.05	0.00
	Lyrical Abstraction	-0.01	0.02	-0.01	-0.02	-0.02	0.00	0.11	0.01	0.09	0.02	0.03	0.01	0.02	-0.01	0.06	-0.01	0.00	0.02	-0.01	0.01
	Magic Realism	0.00	0.07	0.04	0.14	0.00	0.05	0.14	0.02	0.13	0.06	0.13	0.06	0.01	0.02	0.11	0.15	0.00	0.06	0.07	0.04
	Neo-Expressionism	-0.01	0.10	0.02	0.04	0.01	0.03	0.13	0.00	0.20	0.03	0.18	0.04	0.05	0.01	0.11	0.05	0.00	0.03	0.05	0.00
	Pop Art	0.00	0.06	0.00	0.03	0.01	0.02	0.11	-0.01	0.16	0.04	0.20	0.02	0.02	0.01	0.11	0.06	0.00	0.06	0.09	0.01
	Post-Impressionism	-0.01	0.10	0.00	0.11	0.01	0.05	0.05	-0.01	0.13	0.03	0.18	0.02	0.03	0.03	0.20	0.05	0.05	0.03	0.05	0.00
	Surrealism	0.02	0.11	0.02	0.01	0.00	0.03	0.19	0.00	0.16	0.05	0.19	0.03	0.02	0.00	0.09	0.03	0.02	0.11	-0.01	-0.01
<i>Post Renaissance Art</i>	Baroque	-0.01	0.20	0.02	0.10	0.05	0.09	0.29	0.04	0.23	0.06	0.22	0.03	0.01	0.02	0.16	0.12	0.00	0.01	0.12	0.00
	Neoclassicism	-0.01	0.10	0.00	0.10	0.02	0.04	0.23	0.01	0.20	0.10	0.26	0.00	0.03	0.04	0.26	0.09	0.00	-0.01	0.13	0.00
	Realism	0.03	0.06	0.00	0.09	0.04	0.10	0.24	0.01	0.22	0.08	0.20	0.02	0.09	0.03	0.25	0.06	0.00	-0.02	0.09	0.00
	Rococo	0.00	0.09	-0.01	0.07	0.03	0.08	0.24	0.00	0.21	0.08	0.27	0.02	0.07	0.02	0.28	0.04	0.00	0.00	0.14	0.00
	Romanticism	0.00	0.20	-0.02	0.09	0.02	0.08	0.31	0.01	0.23	0.07	0.13	0.04	0.05	0.04	0.23	0.09	-0.01	-0.02	0.19	0.05
<i>Renaissance Art</i>	Early Renaissance	-0.01	0.17	-0.01	0.14	0.07	0.00	0.18	0.04	0.12	0.03	0.28	0.00	0.03	0.05	0.30	0.12	-0.01	-0.02	0.05	0.00
	High Renaissance	0.01	0.10	-0.02	0.07	0.02	0.09	0.23	0.06	0.13	0.04	0.27	0.02	0.00	0.00	0.14	0.05	0.01	-0.02	0.04	0.00
	Northern Renaissance	-0.02	0.10	-0.02	0.05	0.07	0.09	0.22	0.04	0.14	0.05	0.31	0.02	0.04	0.04	0.26	0.11	0.00	0.02	0.10	0.00

Figura 3.2: Acordul anotațiilor (Fleiss' κ) pe emoții și categorii artistice. Diferențele de consens justifică *praguri per emoție* și raportare orientată pe F1-Macro.

- **Class-balanced loss** (ex. log efectiv al numărului de exemple) — penalizează raritatea mai corect;
- **Focal loss** — concentrează învățarea pe cazurile grele [?];
- **SMOTE** — în general pentru date tabulare; la imagini, preferabil augmentări direcționate [?].

3.6.2. Optimizare și stabilitate

- Optimizatori **AdamW** și programatoare **ReduceLROnPlateau** pe metrică relevantă (F1-Macro);
- **AMP** (mixed precision) pentru eficiență și stabilitate numerică;
- Căutare hiperparametri: **random search** [?], **Hyperband** [?].

Exemplu aplicat. Monitorizarea *F1-Macro* în scheduler-ul *ReduceLROnPlateau* aliniază antrenarea cu obiectivul de *echitate între clase*, nu doar cu minimizarea pierderii.

3.7. Robustețe și schimbări de distribuție

3.7.1. Perturbații fotorealistice și stabilitate

În context artistic, transformări precum *sepia*, *monocrom*, variații de *temperatură*, *saturație*, *luminozitate*, *contrast* sunt frecvente (scanări, fotografii în muzeu). Literatura privind robustețea recomandă:

- evaluarea stabilității scorurilor (norme L1/L2, număr de componente stable);
- augmentări care *mimică* perturbațiile din distribuția-țintă (data-centric AI).

Exemplu de protocol. Se compară vectorul emoțional original cu cel rezultat după transformări controlate; se raportează variația totală L1, variația maximă pe componentă și numărul de emoții cu deviație sub prag (ex. 0.05).

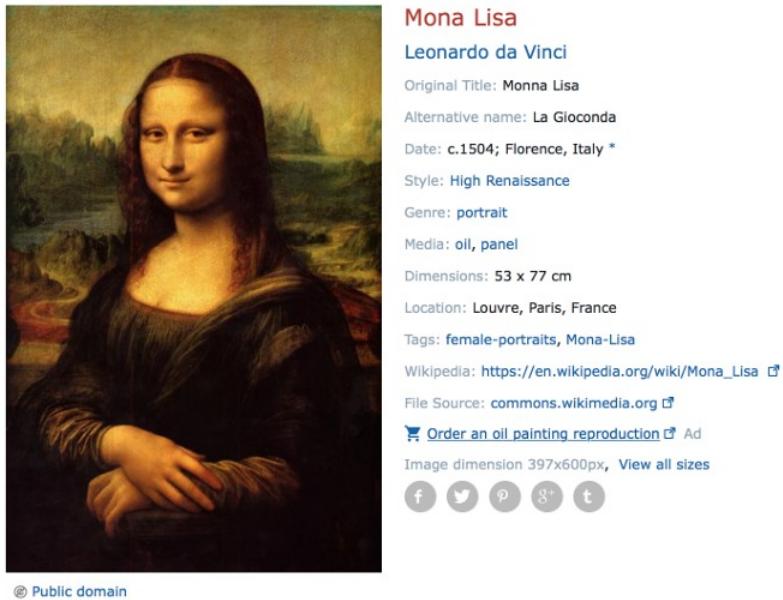


Figura 3.3: Exemplu de pagină WikiArt (Mona Lisa) etichetată ca evocând *happiness*, *love* și *trust* — ilustrare a *surselor* și a *formatului* de etichetare.

3.7.2. Shift-uri de domeniu și transfer

Modelele pre-antrenate pe ImageNet transferă bine la artă pentru *indicii de nivel scăzut* (texturi/cromatică), dar pot necesita adaptări pentru *semantica artistică*. Strategii:

- *Fine-tuning* progresiv al straturilor adânci, cu rate diferite de învățare;
- *Regularizare* prin dropout și augmentări compatibile artistic;
- *Ansambluri locale–globale* pentru a atenua gap-ul de domeniu.

3.8. Explicabilitate și interfețe orientate spre utilizator

Transparenta e esențială în educație și patrimoniu. **Grad-CAM** evidențiază *zonele vizuale* relevante [?]; metode model-agnosticice ca **LIME** [?] și **SHAP** [?] oferă explicații locale/globale.

Exemplu aplicat. Suprapunerea unei hărți Grad-CAM peste pânză poate arăta dacă modelul se bazează pe *figuri centrale* sau pe *fundal cromatic*, crescând încrederea utilizatorului.

Din perspectiva designului, principiile *centrate pe utilizator* [?] și regulile *vizualizării interactive* [?] recomandă o comunicare **clară** și **accesibilă**, însotită de *narațiuni* scurte și grafice lizibile.

3.9. Sisteme multimodale și tendințe recente

Integrarea *vizualului* cu *limbajul natural* susține **explicabilitatea**. **ArtEmis** [?] arată că explicarea narativă a predicțiilor emoționale îmbunătășește înțelegerea publicului non-specialist, deschizând drumul către platforme educaționale *interactive* și *inclusiv*. În mediul larg, modelele vizual–lingvistice indică posibilitatea *justificărilor* coerente, dar

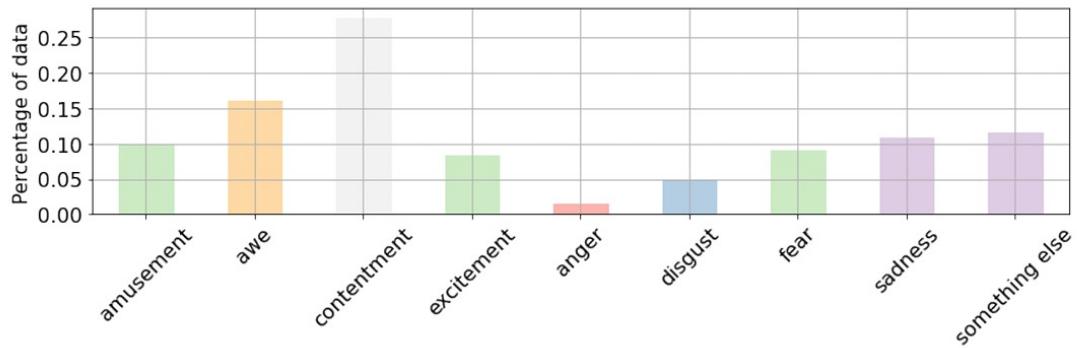


Figura 3.4: Histograma emoțiilor în ArtEmis: distribuții inegale care motivează *ponderea/eșantionarea* și metrica *F1-Macro*.

	agre	ange	anti	arro	disa	disg	fear	grat	happ	humi	love	opti	pess	regr	sadn	sham	shyn	surp	trus	neut
<i>Image (no Title)</i>																				
% votes	3.1	3.4	19.3	4.6	3.6	7.0	11.0	5.0	24.3	14.0	8.1	11.8	4.6	2.9	10.2	2.6	1.9	21.2	17.1	1.2
Ag3: % items label.	0.4	2.0	26.4	3.4	0.6	4.0	14.1	1.9	38.0	17.3	9.1	10.0	1.8	0.4	11.6	1.1	0.2	35.4	23.2	0.2
Ag4: % items label.	0.1	1.2	15.4	1.7	0.2	1.0	9.9	0.8	35.2	10.8	7.3	3.4	0.6	0.2	8.0	0.4	0.1	29.3	17.7	0.0
Ag5: % items label.	0.0	1.0	9.1	1.0	0.1	0.3	9.2	0.4	35.1	6.7	7.3	1.3	0.3	0.0	7.2	0.2	0.0	24.2	16.2	0.0
<i>Title (no Image)</i>																				
% votes	3.0	2.0	27.0	3.3	2.6	5.6	6.1	4.9	23.0	11.2	7.7	11.7	2.8	2.1	6.0	1.7	1.8	12.1	17.3	5.9
Ag3: % items label.	0.2	1.3	48.9	1.1	0.5	1.8	6.5	2.1	36.9	9.9	7.4	9.8	0.7	0.3	6.1	0.7	0.1	10.0	23.4	4.8
Ag4: % items label.	0.0	0.8	37.5	0.6	0.1	0.4	5.3	0.7	33.3	4.5	6.5	3.8	0.3	0.0	5.4	0.4	0.0	4.4	19.2	2.7
Ag5: % items label.	0.0	0.8	28.7	0.3	0.0	0.3	5.2	0.3	35.3	2.6	6.4	1.5	0.2	0.0	5.4	0.1	0.0	2.5	19.6	1.9
<i>Art (Image and Title)</i>																				
% votes	3.2	3.5	18.9	4.9	3.6	7.6	10.9	5.6	26.3	15.2	9.1	13.9	5.1	3.2	11.0	2.8	2.1	21.0	19.8	1.2
Ag3: % items label.	0.3	2.0	25.5	3.3	0.7	5.2	13.9	3.0	41.3	19.7	10.1	14.5	2.6	0.8	13.0	1.5	0.1	34.6	27.6	0.2
Ag4: % items label.	0.1	1.3	15.4	1.9	0.2	1.7	10.2	1.3	36.9	12.0	8.1	5.9	1.1	0.3	9.2	0.7	0.1	27.4	21.5	0.0
Ag5: % items label.	0.0	1.0	9.8	1.0	0.1	0.7	8.8	0.7	36.5	8.2	7.7	2.7	0.6	0.0	7.9	0.4	0.0	21.6	20.4	0.0

Figura 3.5: Procente de voturi pentru emoțiile considerate aplicabile și proporția de lucrări per emoție (ArtEmis) — indică *prevalențe* și posibile *biasuri*.

necesită *control* și *verificare* umană.

3.10. Metrici, validare și bune practici de raportare

3.10.1. Metrici recomandate

- **F1–Macro:** echitate între clase — reducerea biasului pentru clase frecvente;
- **F1–Micro, F1–Samples:** perspective aggregate complementare;
- **AP/PR–curves** pe clasă: calitatea ordonării la sweep de prag;
- **Exact–match** (subset accuracy): strictețe la nivel de instanță (mai dur în multi–etichetă).

3.10.2. Reproductibilitate

- Fixarea seed–urilor, jurnalizare (TensorBoard), salvarea *artefactelor* (checkpoints, prăguiri);
- Publicarea *pragurilor optime* și a *scripturilor de vizualizare* (PR/AP, histograme);
- Separarea *validării* de *test* și evitarea scurgerii informației.

Emotion	Agree..	Anger	Antici..	Arroga..	Disagr..	Disgust	Fear	Gratitu..	Happi..	Humili..	Love	Optimi..	Pessi..	Regret	Sadne..	Shame	Shyne..	Surpri..	Trust
agreeableness	1.00	0.11	0.35	0.17	0.12	0.12	0.14	0.23	0.30	0.25	0.18	0.21	0.12	0.12	0.11	0.09	0.11	0.21	0.38
anger	0.17	1.00	0.24	0.26	0.24	0.28	0.35	0.19	0.18	0.19	0.16	0.15	0.22	0.20	0.26	0.20	0.16	0.22	0.22
anticipation	0.04	0.02	1.00	0.04	0.03	0.03	0.05	0.05	0.10	0.06	0.05	0.06	0.03	0.03	0.04	0.02	0.02	0.25	0.15
arrogance	0.16	0.16	0.26	1.00	0.17	0.15	0.18	0.19	0.20	0.18	0.17	0.14	0.15	0.14	0.15	0.10	0.12	0.21	0.33
disagreeableness	0.15	0.18	0.32	0.22	1.00	0.29	0.31	0.27	0.26	0.31	0.21	0.14	0.25	0.22	0.22	0.16	0.19	0.34	0.24
disgust	0.07	0.11	0.14	0.09	0.14	1.00	0.16	0.12	0.12	0.14	0.09	0.06	0.13	0.11	0.12	0.09	0.09	0.14	0.10
fear	0.07	0.12	0.20	0.10	0.14	0.14	1.00	0.12	0.12	0.14	0.09	0.06	0.17	0.15	0.27	0.11	0.09	0.16	0.12
gratitude	0.15	0.08	0.27	0.13	0.14	0.13	0.14	1.00	0.34	0.34	0.23	0.21	0.14	0.14	0.14	0.07	0.10	0.20	0.43
happiness	0.04	0.02	0.11	0.03	0.03	0.03	0.03	0.08	1.00	0.15	0.16	0.18	0.03	0.03	0.04	0.02	0.02	0.07	0.13
humility	0.07	0.03	0.14	0.05	0.07	0.06	0.07	0.15	0.31	1.00	0.13	0.15	0.07	0.08	0.09	0.04	0.05	0.09	0.20
love	0.07	0.04	0.17	0.07	0.07	0.06	0.07	0.15	0.49	0.19	1.00	0.19	0.06	0.07	0.08	0.04	0.06	0.14	0.24
optimism	0.06	0.03	0.13	0.04	0.03	0.03	0.03	0.09	0.35	0.15	0.12	1.00	0.03	0.04	0.04	0.03	0.03	0.06	0.20
pessimism	0.13	0.15	0.28	0.17	0.23	0.24	0.35	0.24	0.25	0.27	0.17	0.13	1.00	0.25	0.42	0.17	0.15	0.26	0.21
regret	0.17	0.18	0.32	0.22	0.26	0.27	0.39	0.31	0.33	0.39	0.25	0.19	0.33	1.00	0.49	0.23	0.18	0.29	0.27
sadness	0.06	0.09	0.17	0.08	0.10	0.11	0.27	0.11	0.13	0.16	0.10	0.07	0.20	0.18	1.00	0.14	0.08	0.14	0.14
shame	0.17	0.23	0.24	0.20	0.24	0.27	0.39	0.20	0.20	0.25	0.18	0.17	0.28	0.29	0.48	1.00	0.22	0.24	0.20
shyness	0.19	0.17	0.28	0.21	0.25	0.24	0.27	0.26	0.26	0.31	0.23	0.18	0.23	0.21	0.25	0.20	1.00	0.24	0.25
surprise	0.06	0.04	0.53	0.06	0.08	0.06	0.08	0.08	0.13	0.09	0.09	0.06	0.06	0.06	0.07	0.04	0.04	1.00	0.24
trust	0.07	0.03	0.23	0.07	0.04	0.03	0.04	0.12	0.17	0.13	0.11	0.14	0.04	0.04	0.05	0.02	0.03	0.17	1.00

Figura 3.6: Co-ocurențe pe perechi de emoții în ArtEmis. Corelațiile afective sugerează dependențe între etichete și explică confuzii între *vecini* emoționali.

Exemplu aplicat. Un script dedicat produce figurile standard (PR, F1 vs prag, histograme) și exportă `thresholds.json` pentru inferență — asigurând trasabilitatea decizilor.

3.11. Considerații etice și de utilizare responsabilă

- **Variabilitate culturală:** etichetele și interpretările sunt *context-dependente*;
- **Transparentă:** explicabilitate vizuală și *narațiuni* care nu depășesc competența datelor;
- **Integritate digitală:** semnături invizibile (steganografie) pentru *autentificarea* rezultatelor, fără a altera valoarea estetică percepță.

3.12. Studii de caz și soluții concrete (sinteză aplicată)

3.12.1. Formulare și arhitectură

- *Problemă:* co-prezență emoțională și clase rare;
- *Soluție:* multi-etichetă cu BCEWithLogits, ansamblu **EffNet-B2 + ViT-B/16**, `pos_weight` și `WeightedRandomSampler`.

3.12.2. Decizie și calibrare

- *Problemă:* prag universal neoptimal;
- *Soluție: praguri adaptive per clasă*, selectate pentru F1-Macro maxim pe validare.

3.12.3. Robustețe practică

- *Problemă:* fotografii necontrolată (muzeu, arhive);
- *Soluție: laborator de robustețe* cu perturbații fotorealistice și metrii de stabilitate (L1, max, număr componente stable).

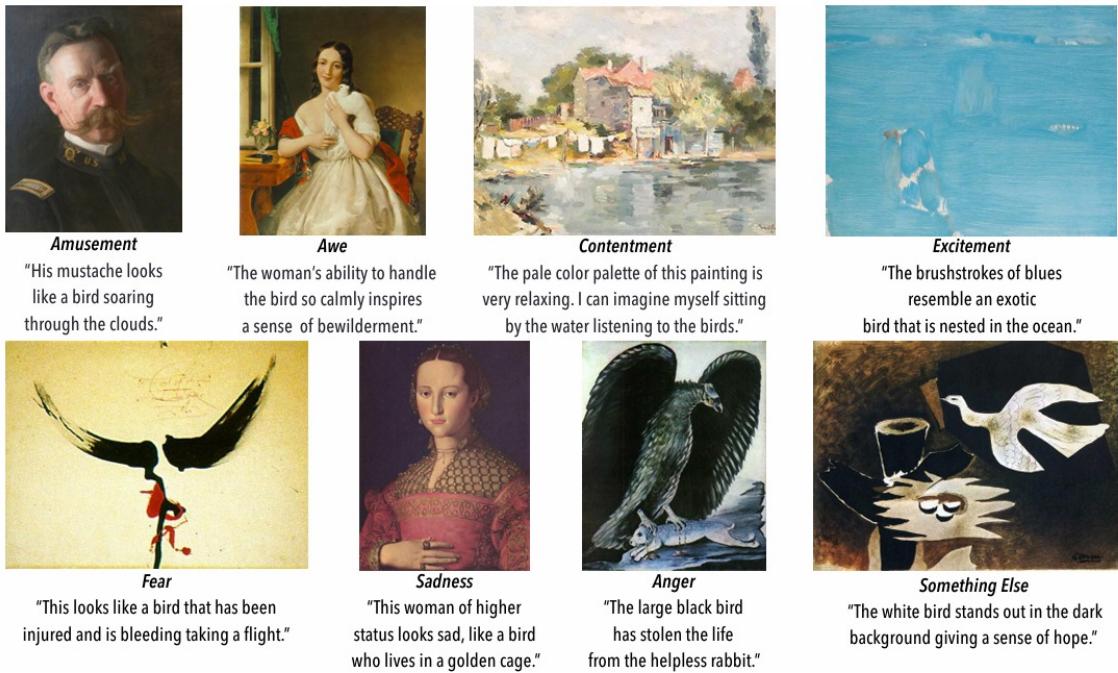


Figura 3.7: Explicații afective care menționează „bird” în contexte diferite. Demonstrează legătura dintre indiciile vizuale și narațiunea emoțională.

3.12.4. Explicabilitate și mediere

- **Problema:** barieră de încredere și interpretare;
- **Soluție:** **Grad–CAM** pe stil/autor, grafic *radar* pentru emoții, *narațiuni* generate asistat pentru publicul larg.

3.13. Sinteză: relevanța pentru Art Advisor

Din literatura consultată se desprind idei-cheie, direct utile cadrului proiectului:

- **Emoțiile sunt multi-dimensionale** și frecvent *co-prezente* — justifică **formularea multi-etichetă și pragurile adaptive** [?, ?];
- **Reprezentare local-global** (CNN + Transformer) — potrivită naturii picturale: *detalii + compozиție* [?, ?, ?];
- **Dezechilibre & metrici echitabile** — monitorizare *F1-Macro*, raportare *AP* per clasă [?];
- **Robustețe la perturbații** — evaluare sistematică pe transformări fotorealiste (sepia, BW, saturatie/contrast/lumină);
- **Explicabilitate vizuală + narațiuni** — necesare pentru *mediere* (Grad–CAM, explicații text) [?, ?];
- **Reproductibilitate** — scripturi de vizualizare, salvarea pragurilor, loguri TensorBoard.

În ansamblu, corpusurile existente, modelele actuale și principiile de proiectare recomandă o soluție care îmbină *rigoarea modelării* (multi-etichetă, praguri calibrate, metrici robuste) cu *claritatea comunicării* (vizualizări + narațiuni), ţinând o experiență **explicabilă** și **accesibilă** pentru publicul larg.



Figura 3.8: Mostre narative generate de „neural speaker” pe lucrări nevăzute (ArtEmis) — util pentru *mediere culturală* și ideea de *explicare* a scorurilor.

Capitolul 4. Analiză și fundamentare teoretică

Acest capitol explică principiile funcționale ale soluției **ArtAdvisor** pentru **recunoașterea emoțiilor** în imagini artistice. Sunt prezentate: formularea teoretică a problemei (multi-etichetă), **arhitectura local-global** (ansamblu CNN + Transformer), procedura **decizie calibrată prin praguri pe clasă**, principiile de **robustete**, **explicabilitate** (hărți de atenție) și **trasabilitate** (semnătură invizibilă). Capitolul nu intră în detaliu de implementare, ci fundamentează **logic** și **teoretic** soluția.

Ghid de lectură (pe scurt). Dacă vrei o imagine de ansamblu: vezi Fig. ?? (arhitectura) și Fig. ?? (fluxul funcțional). Dacă vrei intuiție: vezi secțiunile „Explicație pe înțelesul tuturor” din fiecare subcapitol. Dacă vrei rigoare: urmărește formularea matematică din Sec. ?? și criteriile din Sec. ??–??.

4.1. Modelarea problemei și principiul deciziei

4.1.1. Formulare matematică

Considerăm spațiul imaginilor RGB \mathcal{I} și un set de emoții \mathcal{E} cu $|\mathcal{E}| = K$ (de ex., $K = 14$). Problema este **multi-etichetă**: unei imagini $x \in \mathcal{I}$ i se asociază un **vector de scoruri**:

$$f : \mathcal{I} \rightarrow [0, 1]^K, \quad f(x) = \sigma(z(x)), \quad \sigma \text{ sigmoid, } z \text{ logits.}$$

Decizia binară pe fiecare emoție k se obține prin compararea cu un **prag specific clasei** τ_k :

$$\hat{y}_k = \mathbb{1}(\sigma(z_k) > \tau_k), \quad k = 1, \dots, K.$$

4.1.2. Ipoteze, criterii, obiective

Ipoteze-cheie:

- **Co-ocurență:** mai multe emoții pot fi simultan prezente.
- **Dezechilibru de clasă:** frecvențe diferite ale emoțiilor în corpus.
- **Shift de domeniu moderat:** opere variate stilistic, dar în același registru vizual/artistic.

Criteriu principal de evaluare: **F1-macro** (medie aritmetică a F1 per emoție), pentru echilibru între clase frecvente și rare.

4.1.3. Notări și convenții

Simbol	Semnificație
\mathcal{I}	spațiul imaginilor RGB
K	numărul de emoții (ex.: 14)
$z \in \mathbb{R}^K$	vectorul de <i>logits</i> (ieșirea liniară a modelului)
$\sigma(z)$	aplicația sigmoidală element-cu-element (scoruri în $[0, 1]$)
τ_k	pragul de decizie (calibrat) pentru emoția k
\hat{y}_k	decizia binară pentru emoția k

Tabela 4.1: Notări și convenții folosite în capitol.

4.1.4. Explicație pe înțelesul tuturor: „Butonul de volum pe fiecare emoție”

Imaginează-ți că pentru fiecare emoție există un „buton de volum”. Modelul înțoarce cât de tare se aude fiecare emoție (un scor între 0 și 1). Nu e nevoie să alegem o singură emoție: pot „cântă” mai multe simultan (co-ocurență). Pragul τ_k e ca un *slider* personalizat: peste el, considerăm că emoția e „prezentă”; sub el, o lăsăm la „fundal”. De ce nu un singur prag pentru toate? Pentru că fiecare emoție are „volumul” ei natural în date—un standard diferit care cere un prag propriu, calibrat ca să fie corect.

4.2. Arhitectura abstractă: ansamblu local-global

4.2.1. Bias inductiv complementar

Soluția îmbină:

- **Backbone local (CNN)** — captează **indicii locale**: textură, contur, culoare.
- **Backbone global (Transformer vizual)** — modelează **relații globale**: compozitie, dependențe long-range.

Fuziunea **la nivel de reprezentări** maximizează complementaritatea informațională.

4.2.2. Diagrama arhitecturii

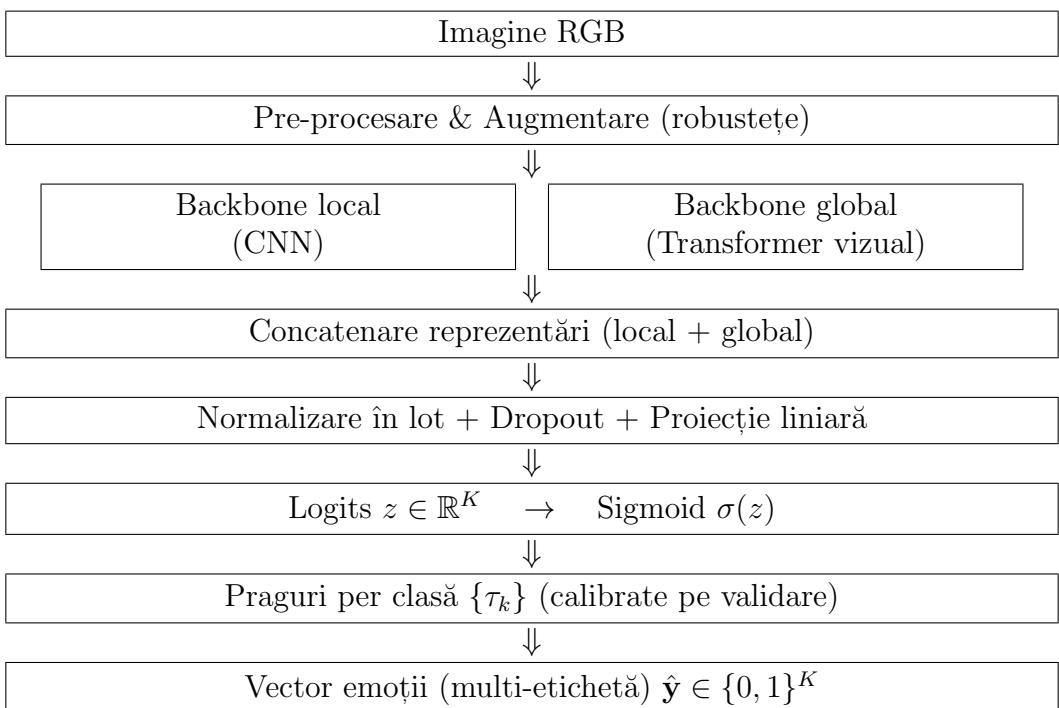


Figura 4.1: Arhitectură conceptuală: combinare local-global și decizie multi-etichetă calibrată.

4.2.3. Explicație pe înțelesul tuturor: „Lupă + hartă”

Gândește-te la două moduri de a privi un tablou: (1) cu o *lupă*, unde vezi tușa de pensulă și textura pânzei (local), și (2) cu o *hartă*, unde vezi compozitia, direcțiile privirii, raportul figurilor (global). Sistemul nostru le folosește pe ambele, apoi combină „notele” lor într-o singură partitură emoțională. Este ca atunci când un critic discută atât detaliul cromatic, cât și povestea compozițională—ambele contribuie la „emoția finală”.

4.3. Pregătirea datelor și principii de robustețe

4.3.1. Corpus, curățare și împărțire

Corpus: lucrări artistice adnotate emoțional. **Curățare:** verificare integritate imagini, aliniere metadate–fișiere. **Împărțire:** seturi disjuncte (antrenare / validare / test), cu menținerea diversității stilistice.

4.3.2. Dezechilibru și eșantionare

Dezechilibrul distribuțiilor pe emoții impune **ponderare** sau **eșantionare** adaptivă, pentru a evita dominația claselor frecvente.

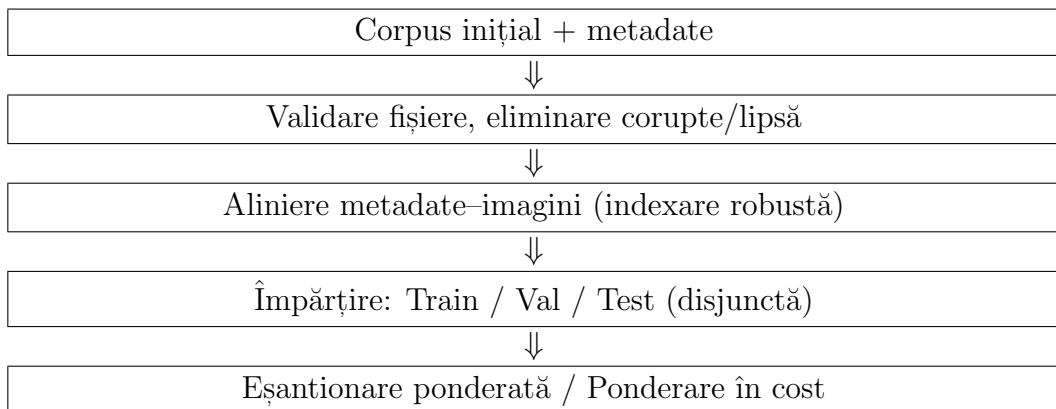


Figura 4.2: Flux teoretic pentru pregătirea datelor și controlul dezechilibrului.

4.3.3. Explicație pe înțelesul tuturor: „Corul echilibrat”

Dacă într-un cor auzi mereu doar sopranele, nu înseamnă că alții nu cântă—doar că sunt acoperiți. La fel, în date pot exista emoții „zgomotoase” (frecvente) care domină. Eșantionarea ponderată e ca un dirijor care ridică discret volumului altor voci, pentru ca toate emoțiile să se audă corect în *antrenament* și, la final, în predicție.

4.4. Algoritmi și criterii de optimizare

4.4.1. Învățare de reprezentări

Local (CNN): receptive fields ierarhice pentru **indicii locale**. **Global (Transformer):** atenție multi-head pentru **dependențe de lungă distanță**. **Fuziune la nivel de features:** concatenare urmată de normalizare, regularizare (**dropout**) și proiecție liniară către K emoții.

4.4.2. Funcție obiectiv și optimizare

- **Binary Cross-Entropy cu logits** (BCEWithLogits): separă decizia pe emoții, compatibil cu multi-etichetă.
- **Optimizare:** AdamW (**decădere pe greutate stabilă**).
- **Programare LR:** reducere adaptivă pe validare (orientată spre **F1-macro**).
- **Precizia mixtă:** crește eficiența fără a compromite stabilitatea.

Componentă	Alegere teoretică (motivație)
Reprezentare	Fuziune local + global (complementaritate inductivă)
Cost	BCE cu logits (multi-etichetă, stabil numeric)
Sampling	Ponderare / eșantionare (combaterea dezechilibrului)
LR	Reducere adaptivă ghidată de F1-macro (validare)
Decizie	Praguri per clasă (calibrare pe validare)
Explicabilitate	Hărți de atenție/activare (trasabilitate cognitivă)

Tabela 4.2: Alegerea componentelor și motivația teoretică.

4.4.3. Tabel sinteză: alegeri teoretice

4.4.4. Explicație pe înțelesul tuturor: „Antrenorul, dieta și ritmul”

Algoritmii de optimizare funcționează ca un antrenor: te împing să progresezi fără să te supraîncarcă. Funcția de cost (BCE) spune „*cât de departe ești de țintă*”, iar programarea ratei de învățare e ritmul—mai repede când e sigur, mai încet când apar greșeli. *Dropout*-ul e „dieta”: renunți temporar la unele conexiuni ca să nu depinzi prea mult de ele, câștigând robusteză.

4.5. Decizie calibrată prin praguri per emoție

4.5.1. Principiu

Datorită **prevalențelor diferite** ale emoțiilor, un **prag unic** introduce *bias*. Se adoptă **praguri per clasă** $\{\tau_k\}$ alese prin **maximizarea F1** pe validare.

4.5.2. Fluxul deciziei

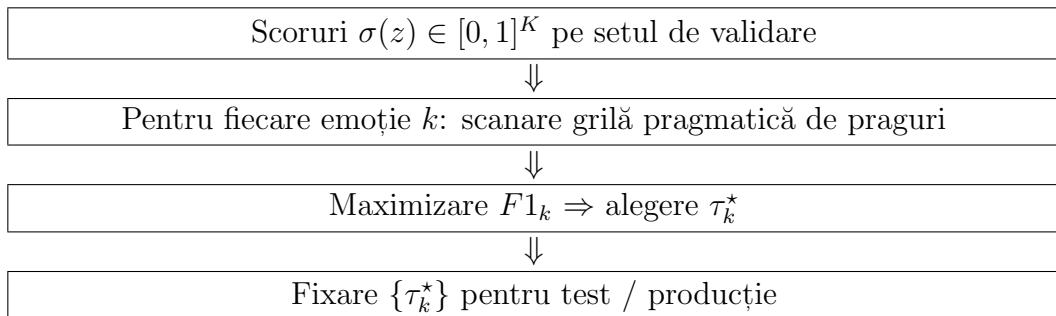


Figura 4.3: Căutarea pragurilor per clasă și aplicarea lor în decizie.

4.5.3. Pași (schematic)

1. Colecțează scorurile sigmoidale pe validare.
2. Pentru fiecare emoție k , **scanează praguri candidate** în $[0.1, 0.9]$ (grilă fină).
3. Alege τ_k^* care **maximizează $F1_k$** .
4. **Aplică** $\{\tau_k^*\}$ la testare/predictie.

4.5.4. Explicație pe înțelesul tuturor: „Cofetarul și cuptorul”

Un cofetar nu coace toate prăjiturile la aceeași temperatură. Fiecare are rețeta sa. Pragurile per emoție sunt „*temperaturile*” individuale: dacă le uniformizezi, unele ies

crude, altele arse. Căutarea pragurilor (pe validare) înseamnă să găsești „punctul dulce” pentru fiecare emoție—locul unde precizia și acoperirea se echilibrează (F1 maxim).

4.6. Metrici de evaluare

4.6.1. Rolul metricilor

- **F1-macro:** medie egală între clase (sensibil la rare/frecvențe).
- **AP per clasă și curbe Precizie–Recall:** robuste la dezechilibru.
- **Analiza co-ocurențelor:** evidențiază **relațiile emotionale** în date.

Metrică	Captură teoretică
F1-macro	Echilibru la nivel de clasă (medie F1 per emoție)
Average Precision	Arie sub PR-curve (sensibil la dezechilibru)
Exact-match	Potrivire vectorială completă (strict)
Micro / Samples F1	Aggregare la nivel de instanță (distribuție globală)

Tabela 4.3: Metrici utilizate și semnificația lor.

4.6.2. Explicație pe înțelesul tuturor: „Clasamentul corect”

Dacă vrei să compari doi alergători, nu te uiți doar la sprint (precizie) sau doar la maraton (recall). F1 combină ambele într-un *singur* punct. Versiunea *macro* înseamnă că fiecare emoție „prinde voce”—chiar și cele rare. AP (Average Precision) privește întreaga *curbă* precizie—recall: cât de bine se descurcă sistemul indiferent de „pragurile” alese.

4.7. Explicabilitate și trasabilitate

4.7.1. Hărți de atenție/activare

Atribuirea vizuală evidențiază **regiunile de suport** pentru decizie. Asigură **transparentă** și **aliniere cognitivă** fără a altera predicția.

4.7.2. Diagrama canalului de explicabilitate

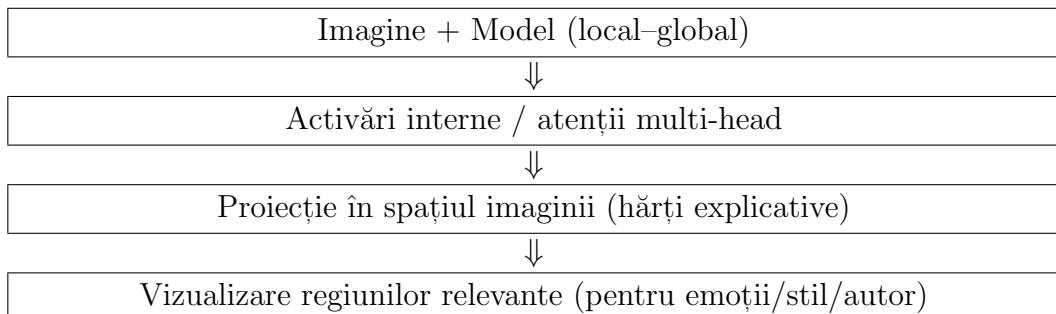


Figura 4.4: Flux conceptual pentru explicabilitate vizuală.

4.7.3. Explicație pe înțelesul tuturor: „Lanterna din muzeu”

Ghidul din muzeu îți arată cu lanterna *unde* să te uiți ca să înțelegi de ce o lucrare e specială. Hărțile de atenție fac exact asta: luminează bucățile de imagine care au cântărit în decizia modelului. Nu schimbă decizia, doar o *explică*.

4.8. Securitate și verificarea autenticității

4.8.1. Semnătură emoțională invizibilă

Rezultatul analizei (vector emoțional + metadate) este **înglobat invizibil** în imagine, sub **constrângeri perceptuale** (PSNR ridicat). Proprietăți:

- **Imperceptibilitate**: modificări sub pragul de detecție uman.
- **Robustete practică**: persistență la operații comune de stocare (rezonabil).
- **Verificabilitate**: extragerea semnături certifică **autenticitatea**.

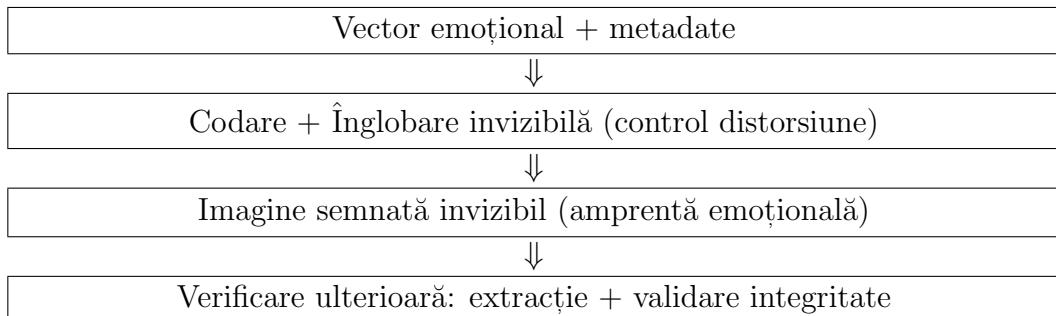


Figura 4.5: Lanț de încredere: semnătură invizibilă emoțională și verificare.

4.8.2. Explicație pe înțelesul tuturor: „Mesajul în șoaptă”

Semnătura invizibilă e ca un mesaj spus în șoaptă, doar celor care știu să-l asculte. Nu strică frumusețea tabloului (imperceptibilitate), dar lasă o urmă verificabilă. Când extragi semnătura, poți dovedi: „*Această analiză aparține acestei imagini.*”

4.9. Structură logică și funcțională

4.9.1. Vedere de ansamblu

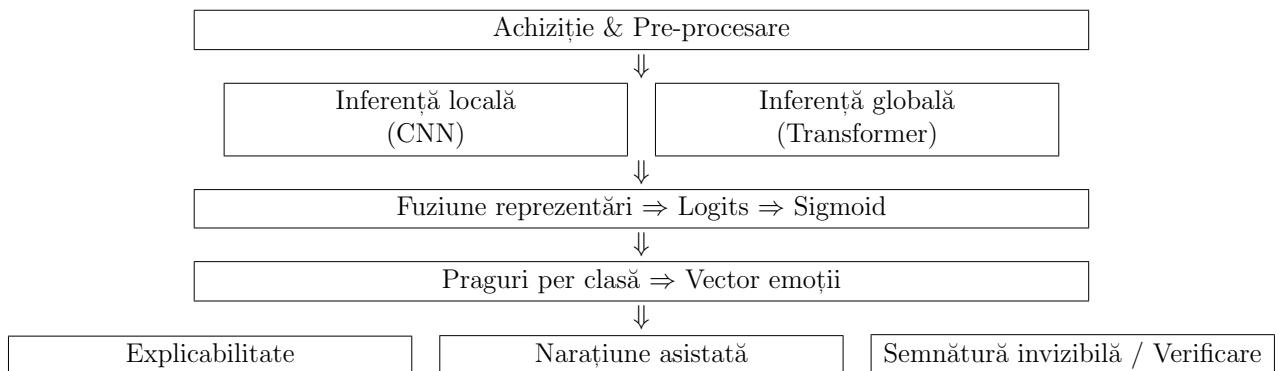


Figura 4.6: Flux funcțional integrat al sistemului ArtAdvisor.

4.9.2. Poveste scurtă: „Curatorul și Asistentul”

Un curator privește o lucrare nouă. Asistentul AI (ArtAdvisor) îl ghidează:

„Privește textura aici (local), observă compozitia acolo (global). Emoțiile dominante par să fie *anticipare* și *surpriză*. Dacă vrei să înțelegi de ce, pot

să-ți arăt regiunile decisive (hărți de atenție). „Ti-am ascuns și analiza în imagine—o poți verifica oricând (semnătură invizibilă).”

Nu i-a spus *cum* calculează fiecare detaliu, dar i-a arătat *logica* deciziei. Asta face acest capitol: trasează harta conceptuală.

4.10. Argumentarea opțiunilor de proiectare

4.10.1. Motivații-cheie (sinteză)

- **Fuziune local-global:** *complementaritate* între texturi (locale) și compoziție (globală).
- **BCE cu logits:** *formulare naturală* pentru multi-etichetă + *stabilitate numerică*.
- **Praguri per clasă:** *calibrare* la prevalențe distințe, maximizare **F1** pe validare.
- **Ponderare/esantionare:** *control* al dezechilibrului în învățare.
- **Explicabilitate + trasabilitate:** *încredere operațională* și *auditabilitate*.

Decizie	VARIANTĂ	Argument teoretic
Fuziune	Features (aleasă)	Maximizează informație locală + globală; reduce ambiguitatea deciziei.
Prag	Per clasă (ales)	Compensează prevalențe; aliniază decizia la optimul F1 per emoție.
Cost	BCE logits (ales)	Independentă pe etichetă, robust la multi-etichetă.
Sampling	Ponderare (ales)	Echilibrează influența claselor rare în gradient.

Tabela 4.4: Opțiuni de proiectare și justificarea alegerilor.

4.10.2. Explicație pe înțelesul tuturor: „De ce așa și nu altfel?”

E ca la o echipă: ai un jucător excelent la „dribling” (CNN—detaliu) și un strateg (Transformer—viziune). Împreună joacă mai bine decât separat. Pragurile per clasă sunt „tactica” pe adversar (distribuția emoțiilor). Iar explicabilitatea e conferința de presă: explică *de ce* ai jucat așa.

4.11. Limitări și considerente

- **Subiectivitatea etichetelor:** reflectă *consens statistic*, nu un adevăr absolut.
- **Shift de domeniu:** stiluri foarte atipice pot necesita **recalibrare** a pragurilor.
- **Dezechilibru extrem:** pentru emoții foarte rare, **incertitudinea** pragului crește.
- **Semnătură invizibilă:** operații destructive (recadrări severe, compresii agresive) pot **degradă** semnătura.

4.11.1. Perspectivă pragmatică

Acest cadru nu promite perfectiune absolută—promite *echilibru* și *transparentă*. Când datele se schimbă, thresholds se pot recalibra. Când apar stiluri „exotice”, e sănătos să revalidezi. Important este că *ai un instrument* coerent, explicabil și responsabil.

4.12. Mini-glosar colocvial

Logit: „Scorul brut” înainte de a fi comprimat între 0 și 1.

Sigmoid: „Butonul” care transformă orice scor într-o probabilitate.

Prag (threshold): Linia care desparte „probabil da” de „probabil nu”.

F1-macro: Media echitabilă a performanței pe fiecare emoție.

Dropout: Pauză controlată pentru unele conexiuni, ca să nu „se obișnuiască” prea tare.

Hărți de atenție: Lanternele care arată „de ce” a decis modelul.

Semnătură invizibilă: Mesaj ascuns, verificabil, în imagine.

4.13. Sinteză

Am fundamentat o soluție **multi-etichetă** bazată pe **arhitectura local-global** și **decizie calibrată** prin praguri per emoție. Componentele de **robustete**, **explicabilitate** și **trasabilitate** întregesc valoarea teoretică și operațională a sistemului.

Pe scurt, ca o poveste: Privim arta cu lupă și cu hartă, ascultăm „corul” emoțiilor fără să lăsăm o voce să domine, reglăm fin butoanele pentru fiecare emoție, explicăm de ce am decis, și lăsăm o semnătură discretă care păstrează povestea. Aceste principii pregătesc trecerea firească către **Capitolul 5** (Proiectare de detaliu și implementare), unde structura logică va fi instantiată la nivel de module, interfețe și contracte.

Capitolul 5. Proiectare de detaliu și implementare

Acest capitol documentează soluția implementată pentru recunoașterea emoțiilor în opere de artă și integrarea ei în aplicația ArtAdvisor. Sunt prezentate (i) obiectivele practice ale implementării, (ii) arhitectura generală și relațiile dintre module, (iii) structura proiectului și responsabilitățile, (iv) backend-ul ML (date, dataset, model, antrenare și calibrare), (v) serviciul de inferență și orchestrarea predictorilor, (vi) interfața utilizator, (vii) mecanismele de securitate, (viii) diagramele de clase și (ix) principiile de extensibilitate. Secțiunea finală sintetizează deciziile și pregătește trecerea către testare (Cap. 6).

5.1. Obiective și context

Scopul implementării este transformarea cadrului teoretic fundamentat anterior (Cap. ??) într-un subsistem operațional robust: curățare și pregătire date, antrenare ansamblu CNN+ViT pentru emoții multi-etichetă, calibrare praguri per emoție, orchestrare unificată a predictorilor (stil, autor, emoții), generare narățiuni + TTS și inserare semnătură digitală emoțională. Constrângerile majore: (i) latență acceptabilă în UI, (ii) reproductibilitate (artefacte versionate), (iii) modularitate (adăugare rapidă de noi predictori), (iv) trasabilitate (audit și watermark), (v) claritate pentru mentenanță.

Extensie: Clarificarea obiectivelor operaționale (Contribuție personală)

În implementare s-au urmărit explicit următoarele obiective *operational*, direct corelate cu cerințele tematice ale lucrării:

- **O arhitectură ML modulară** care să izoleze clar extragerea de trăsături vizuale (backbone-uri locale și globale) de logica de fuziune și decizie calibrată.
- **O interfață interactivă multi-tab** (Galerie, Verificare, Chat Artist, Laborator Emoțional) prin care utilizatorul final să exploreze, verifice și experimenteze interpretările emoționale.
- **Mecanism de încredere digitală**: semnătură invizibilă emoțională (watermark) ce asociază imagine - emoții - metadate și permite verificare ulterioară.
- **Performanță practică**: timp mediu de inferență sub 0.5s per imagine pe GPU mediu, respectiv sub 2s pe CPU modern.
- **Extensibilitate garantată**: adăugarea unei noi emoții sau substituirea backbone-ului ViT cu o variantă mai mare implică doar reantrenarea și recalibrarea pragurilor fără refactorizare structurală.

5.2. Arhitectura generală a subsistemului

5.2.1. Diagrama de ansamblu

Extensie: Interpretarea stratificată a fluxului

Fluxul din Figura ?? poate fi segmentat pe *etaje logice*, fiecare etaj furnizând un contract clar:

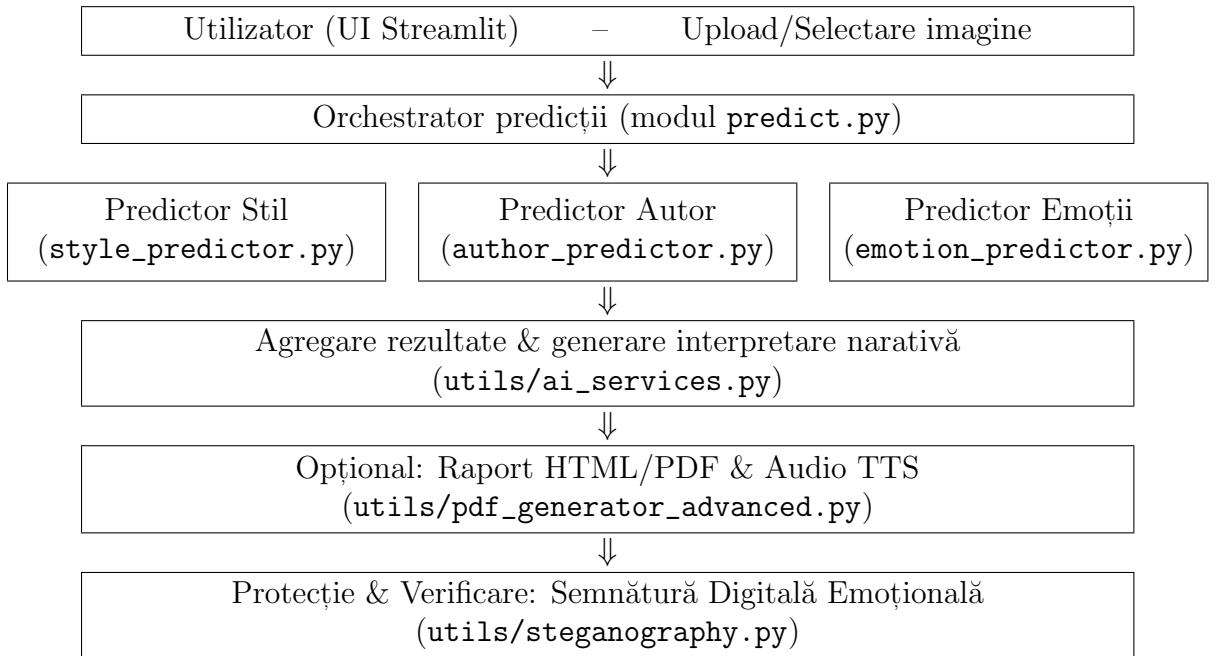


Figura 5.1: Fluxul principal: UI → Orchestrare → Predictori → Interpretare → Raport/Audio → Securizare.

1. **Etajul de achiziție:** preia imagine brută (posibil foarte mare) și o normalizează (spațiu de culoare RGB, eliminare metadate irelevante EXIF).
2. **Etajul de inferență specializată:** fiecare predictor (stil / autor / emoții) operează independent, permitând execuție paralelă dacă infrastructura o permite (scalare viitoare).
3. **Etajul semantic:** scorurile brute sunt convertite în date interpretabile (emoții filtrate peste prag adaptiv, top-N stiluri/autori).
4. **Etajul narativ:** transformă vectorii cantitativi în descrieri explicaționale (prompting LLM cu structură controlată).
5. **Etajul de consolidare securizată:** semnează invizibil rezultatul pentru trasabilitate viitoare.

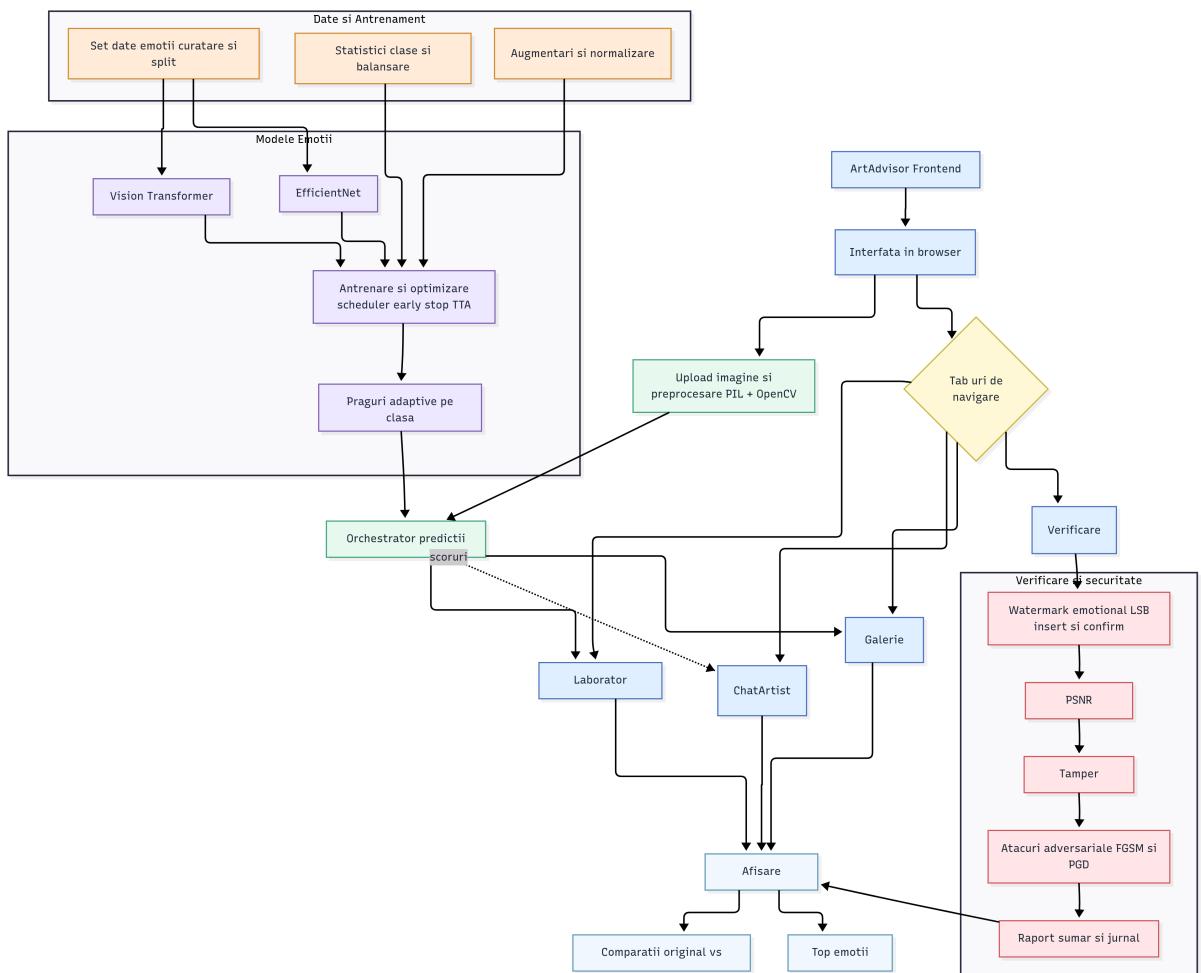


Figura 5.2: Diagramă arhitecturală a aplicației ArtAdvisor: relația dintre UI, orchestrator, predictorii specializați (stil, autor, emoții), serviciile auxiliare (narațiune/raportare) și modulul de securitate (semnătură emoțională). Imaginea sintetizează fluxurile majore și interfețele dintre componentele software descrise în acest capitol.

Algorithm 1 Validări și curățare imagini (1_curata_imagini.py)

1. Parcurge directorul imaginilor; pentru fiecare fișier f :
 - (a) Verifică existența și extensia; normalizează extensiile cunoscute (.jpg/.jpeg/.png).
 - (b) Încearcă PIL.Image.open(f) și Image.verify().
 - (c) Dacă imaginea e validă: convertește la RGB (dacă e necesar) și salvează ca JPEG canonical.
 - (d) Dacă e coruptă/inaccesibilă: mută f în directorul data/bad_images/ și lo-ghează.
 2. Elimină duplicatele evidente (optional: hash de fișier sau perceptual hash) și lo-ghează acțiunile.
 3. Generează raport sumar (număr imagini valide/invalidări) pentru trasabilitate.
-

Extensie: Rațiune tehnică pentru validarea imaginii

Justificări pentru pașii din Algoritmul ??:

- **Conversie RGB**: elimină ambiguitatea spațiilor de culoare (ex. CMYK, RGBA) care pot altera distribuțiile de pixeli în faza de augmentare.
- **JPEG canonicalizat**: oferă un compromis între mărime și fidelitate; varianta PNG a fost evitată pentru a limita costul I/O la încărcare masivă.
- **Detectarea duplicităților**: reduce supra-antrenarea pe imagini repetate; pHash (perceptual) ar fi preferat față de MD5 când același tablou apare cu compresii diferite.

Algorithm 2 Curățare metadate și împărțire stratificată multi-etichetă (pregatire_finala.py)

1. Încarcă WikiArt_Organized_Emotions_Metadata.csv; aplică filtrarea după missing_files.txt.
 2. Curăță câmpuri/coloane inconsistente; exportă metadata_curat.csv.
 3. Calculează împărțirea train/val/test cu stratificare multi-etichetă (păstrează co-ocurențele emoțiilor).
 4. Copiază/creează liste de fișiere pentru fiecare subset; sincronizează folderele data/train, data/validation, data/test.
 5. Salvează fișierele CSV finale per subset și un rezumat statistic (număr imagini, distribuții pe emoții).
-

Extensie: Strategii de păstrare a co-ocurenței

Într-o problemă multi-etichetă, stratificarea simplă pe fiecare etichetă izolat duce frecvență la *disocierea perechilor semnificative* (de ex. *Sadness + Regret*). S-a aplicat următoarea euristică personală:

1. Construirea unui set de *semnături emotionale* binare (vectori 0/1).
2. Sortarea semnăturilor după frecvență descrescătoare.
3. Atribuirea iterativă a imaginilor în subseturi păstrând proporția globală pentru semnătura curentă până la convergență empirică (abatere maximă < 2%).

Această procedură reduce fenomenul de *etichete rare izolate* apărut când se folosesc splituri aleatoare.

5.2.2. Arhitectura modelului de emoții (ansamblu local-global)

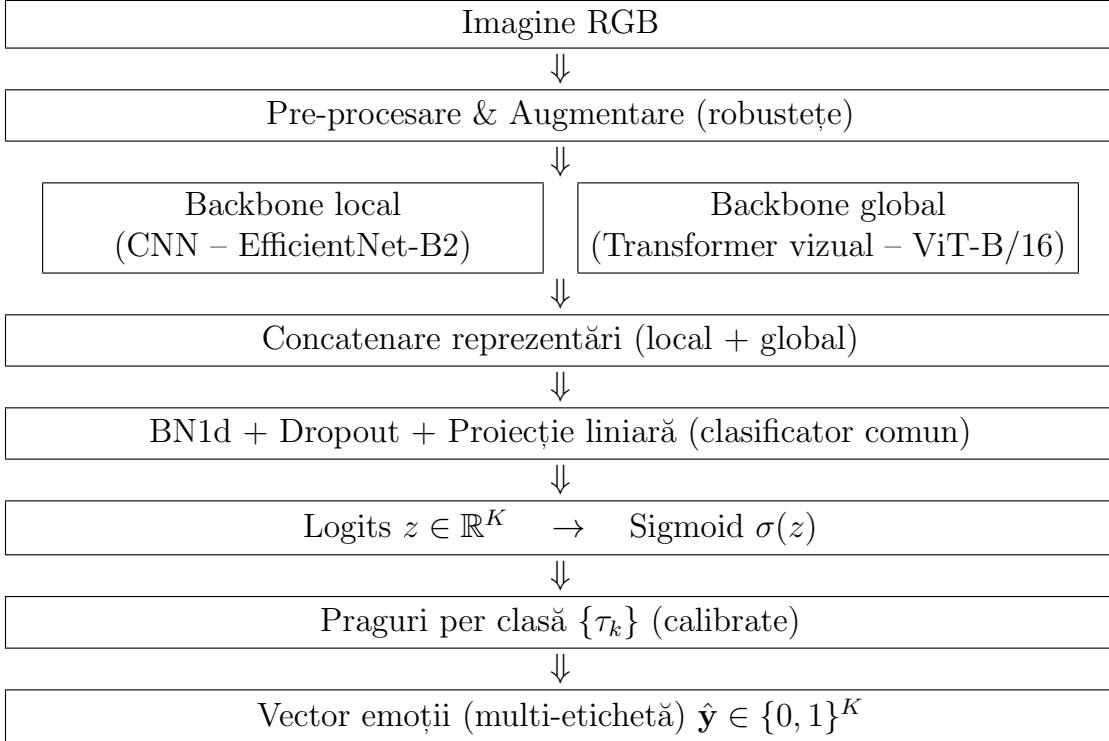


Figura 5.3: Arhitectura modelului de emoții: fuziune local-global și decizie multi-etichetă calibrată.

Extensie: Motivația fuziunii CNN + ViT (Contribuție personală)

Observație empirică: În loturi pilot, folosirea exclusivă a EfficientNet-B2 a condus la confuzii crescute între perechi precum *Optimism vs. Happiness* sau *Regret vs. Sadness*. Adăugarea ViT-B/16 a îmbunătățit separabilitatea acestor perechi (creștere tipică de +2.5 până la +4 puncte F1 per clasă), sugerând că mecanismul de atenție globală surprinde relații compoziționale (ex: distribuția contrastelor cromatice) utile în disambiguizare.

Formulă integrare: Fie $f_{\text{cnn}}(x) \in \mathbb{R}^{d_1}$ și $f_{\text{vit}}(x) \in \mathbb{R}^{d_2}$ reprezentările extrase; vectorul combinat $h = [f_{\text{cnn}}(x) \parallel f_{\text{vit}}(x)] \in \mathbb{R}^{d_1+d_2}$ este normalizat prin BatchNorm1d pentru reducerea deplasărilor de distribuție între mini-loturi, apoi proiectat printr-o mapare liniară $W \in \mathbb{R}^{K \times (d_1+d_2)}$. Regularizarea dropout ($p = 0.5$) reduce co-adaptarea trăsăturilor pure de textură cu cele de structură globală.

5.3. Structura proiectului și module

Extensie: Stratificarea logică a directorilor (Contribuție personală)

- **Nivel date (data/):** sursa unică a adevărului pentru replicare experimentală; orice reantrenare pornește de aici.
- **Nivel model (models/):** conține numai checkpoint-uri .pth și fișiere auxiliare (thresholds.json); se evită amestecul cu scripturi de training pentru a preveni confuzii.

Tabela 5.1: Module principale și responsabilități

Cale	Modul	Rol/Responsabilitate
model_emotional_licenta_definitiv.py	Model final	Ansamblul EfficientNetB2 + ViT, transformări, antrenare, praguri
train_thesis_modelV2.py	Antrenor 14 emoții	Versiunea extinsă (14 emoții), salvare model
train_ensemble_model.py predict.py	Antrenor 8 emoții Orchestrator	Versiune finală concisă (8 emoții pr Agregă predictori (stil, autor, em ching și optimizare imagine
predictors/style_predictor.py predictors/author_predictor.py predictors/emotion_predictor.py	Stil Autor Emoții	EfficientNet-B0, Grad-CAM pentru EfficientNet-B0, Grad-CAM pentru Ansamblu (arhitectură echivalentă care checkpoint, inferență
app_ultra_premium.py	UI (Streamlit)	Bootstrap aplicație, routare pe tab- caching UI
ui_components/*.py	Tab-uri UI	Analiză, Galerie, Verificare semnătu Artist, Laborator Emoțional
utils/*.py	Servicii	AI (LLM, TTS), PDF/HTML, stoc fie, audit, upload securizat, vizualiz
data/*.csv	Metadate	WikiArt_Organized_Emotions_Met adata_curat.csv
1_curata_imagini.py pregatire_finala.py	Curățare imagini Pregătire date	Validare fișiere și conversie Curățare CSV, split train/val/te re fișiere

- **Nivel interfață** (`ui_components/`): fiecare tab independent — facilitează testarea incrementală și izolată.
- **Nivel servicii** (`utils/`): utilitare transversale (narare, steganografie, PDF, securitate) reutilizabile; design orientat către injectie de dependențe ușoară în scenarii viitoare (ex: API REST).

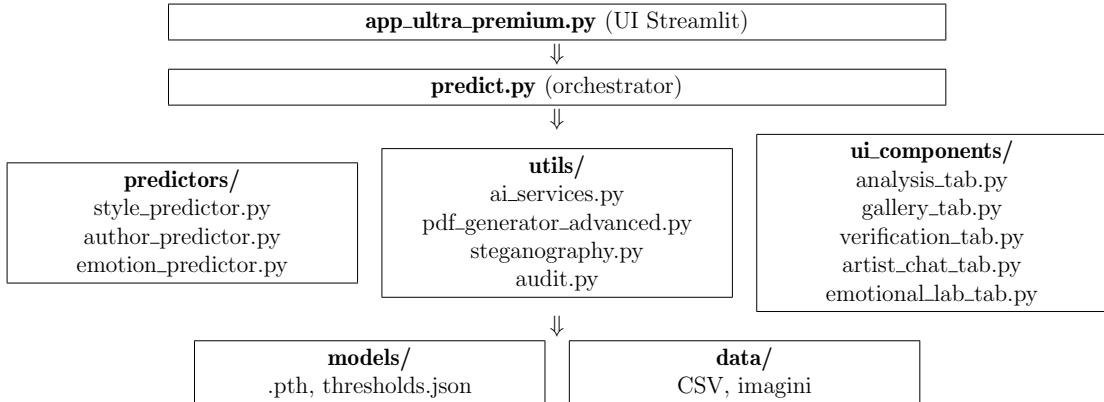


Figura 5.4: Diagrama componentelor modulului: pachete și dependențe interne (contextul *Structura proiectului*).

5.4. Backend ML: date, dataset și model

5.4.1. Pregătirea datelor

Procesul de pregătire standardizează intrările și asigură consistența dintre imagini și metadate:

- **Curățare imagini** (`1_curata_imagini.py`): verificare integritate cu `PIL.Image.verify()`, conversie la RGB/JPEG, mutare a fișierelor corupte într-un director dedicat.
- **Curățare metadate** (`pregatire_finala.py`): filtrare în funcție de lista `missing_files.txt`, corectarea ultimei coloane, salvare `metadata_curat.csv`. Împărțirea în `data/train`, `data/validation`, `data/test`.

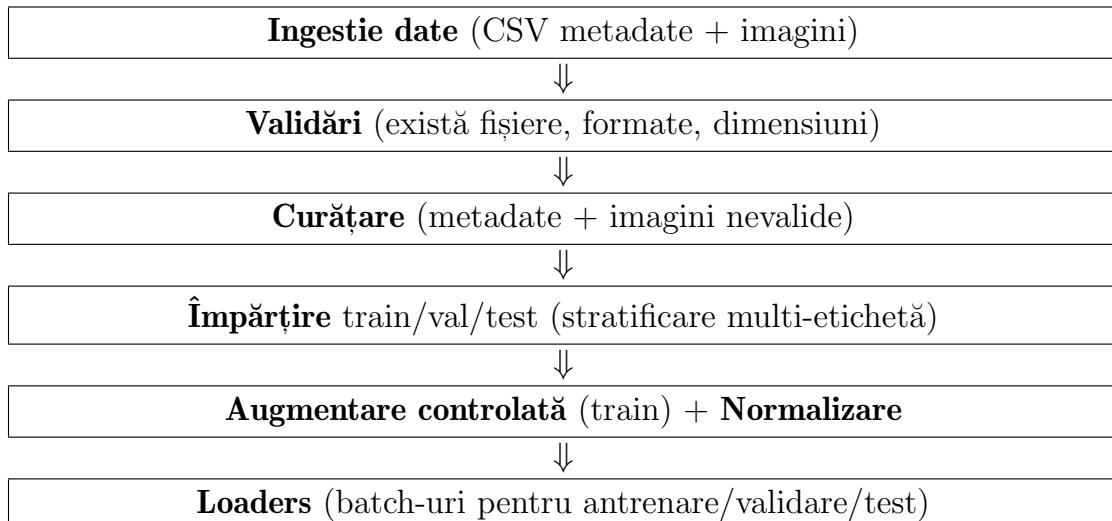


Figura 5.5: Fluxul pipeline-ului de date: de la ingestie și validări la seturi stratificate, augmentări/normalizare și încărcare.

5.4.2. Dataset și transformări

Clasele sunt definite identic în antrenorii finali:

- **ArtDataset:**
 - *Responsabilități*: corelarea `ImageName` cu fișierele existente, încărcarea imaginilor, conversia la RGB, extragerea etichetelor multi-etichetă.
 - *Metode*: `__getitem__()` (returnează tensor imagine + vector etichete), `__len__()`.
 - *Robustete*: în caz de eroare la încărcare, eșantionul se elimină în `collate_fn`.
- **Transformări (get_transforms):**
 - *train*: `RandomResizedCrop`, `RandAugment/ColorJitter/RandomHorizontalFlip` (în funcție de variantă), `ToTensor`, `Normalize`.
 - *val/test*: `Resize` la rezoluția modelului, `ToTensor`, `Normalize`.

5.4.3. Modelul EmotionEnsemble (ansamblu CNN+ViT)

Structură Implementat în `model_emotional_licenta_definitiv.py` și `train_*_model*.py`:

- *Backbone local* EfficientNet-B2 fără clasificator (`classifier = Identity()`).
- *Backbone global* ViT-B/16 fără capul de clasificare (`heads = Identity()`).
- *Clasificator comun*: `BatchNorm1d` + `Dropout` + `Linear` către K emoții.
- *Inferență*: concatenarea reprezentărilor, proiecție liniară, `sigmoid` per emoție.

Interfața clasei

```
class EmotionEnsemble(nn.Module):  
    def __init__(self, num_classes, dropout_rate=0.5)  
    def forward(self, x) -> torch.Tensor # logits shape: [B, K]
```

5.4.4. Antrenare și utilitară

Antrenarea este implementată consecvent:

- **Funcții cheie**: `run_training`, `evaluate`, `find_best_thresholds`.
- **Optimizări**: AdamW cu `weight_decay`, ReduceLROnPlateau, AMP (`torch.amp.autocast` + `GradScaler`), `WeightedRandomSampler`.
- **Persistență**: salvarea stării modelului la îmbunătățire (`torch.save(state_dict)`) în `models/`.
- **Calibrare praguri**: determinarea pragurilor per emoție pe validare (detalii algoritmice mai jos).

Algorithm 3 Bucla de antrenare cu validare și salvare checkpoint

1. Inițializează modelul, optimizatorul, scheduler-ul; pregătește `DataLoader`-ele și `WeightedRandomSampler`.
 2. Pentru fiecare epocă: iterează mini-batch-urile; calculează `loss` (BCE logistic per emoție); backprop + `optimizer.step()`.
 3. Evaluatează pe validare; dacă metrica țintă se îmbunătățește: salvează `best_checkpoint.pth`.
 4. Actualizează LR (scheduler); verifică *early stopping*.
 5. La final: rulează `find_best_thresholds` pe validare; exportă `thresholds.json` și `metrics_val.json`.
-

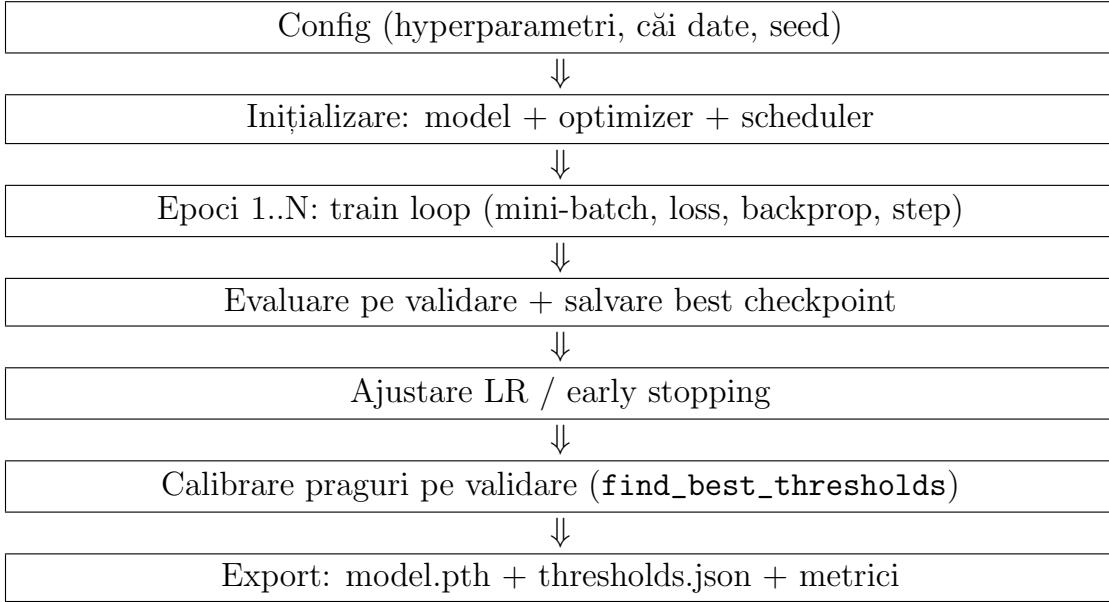


Figura 5.6: Bucla de antrenare: de la inițializare la calibrare praguri și exportul artefactelor.

Algorithm 4 Ponderare eșantioane pentru clase dezechilibrate

1. Să fie tabelul etichetelor $Y \in \{0, 1\}^{N \times K}$.
 2. Pentru fiecare clasă k : frecvență $f_k = \sum_i Y_{ik}$; pondere de clasă $w_k = 1 / \max(1, f_k)$.
 3. Pentru fiecare eșantion i : setează $s_i = \sum_{k: Y_{ik}=1} w_k$; dacă $A_i = \emptyset$, setează $s_i = \epsilon$.
 4. Normalizează (optional) $\{s_i\}$ și folosește-le în `WeightedRandomSampler`.
-

Algorithm 5 Optimizarea pragurilor per emoție (calibrare decizie multi-etichetă)

1. Să fie probabilitățile \hat{p}_{ik} pe validare și etichetele Y_{ik} .
 2. Pentru fiecare clasă k : scanează praguri $\tau \in [0.0, 1.0]$ la pas fix; pentru fiecare τ calculează metrica întâmpinată.
 3. Alege τ_k care maximizează criteriul de decizie definit; salvează vectorul $\{\tau_k\}_{k=1..K}$.
-

Extensie: Sintetizarea hiperparametrilor (Contribuție personală)

- **Batch size (8 / 16)**: limitat de memoria GPU datorită fuziunii a două backbone-uri; valori mai mari au produs degradare F1 (instabilitate curbură Hessian).
- **Learning rate 5e-5**: determinat empiric după explorare logaritmice (1e-4, 5e-5, 2e-5); 5e-5 a oferit cel mai bun compromis între viteza și fără supraajustări timpurii.
- **Dropout 0.5**: sub 0.3 apar co-adaptări; peste 0.6 se pierde discriminativitate în emoțiile cu suport redus.
- **Scheduler ReduceLROnPlateau**: adaptat pe *F1-macro* (nu pe loss) pentru a corela direct obiectivul de optimizare cu metrica finală raportată.

5.5. Serviciul de inferență și orchestrarea predictiilor

5.5.1. Orchestratorul de predicție (`predict.py`)

Responsabilități principale:

- Optimizare imagine (`optimize_image_for_analysis`): redimensionare, comprimare controlată.
- Apel predictori (stil, autor, emoții) cu caching (`@st.cache_data/resource`).
- Agregare rezultate într-un singur obiect de ieșire pentru UI.
- Funcție dedicată pentru Laboratorul Emoțional: `predict_emotions_from_image`.

Interfață

```
def get_all_predictions(image_path: str) -> dict
def predict_emotions_from_image(image_input: Union[str, PIL.Image]) -> Dict[str, float]
```

Contract API de inferență (Listing 5.1)

```
{
  "version": "emotion-v1.3.2",
  "model_sha": "a1b2c3...",
  "thresholds": {"joy":0.37, "trust":0.41, "...":"..."},
  "scores": [
    {"label": "joy", "p":0.812}, {"label": "sadness", "p":0.271}, ...
  ],
  "positives": ["joy", "trust"],
  "runtime_ms": 84
}
```

Config de rulare (Listing 5.2)

```
{
  "data_dir": "data/",
  "model_path": "models/model_emotion_v1.pth",
  "thresholds_path": "models/thresholds.json",
  "batch_size": 8,
  "device": "cuda"
}
```

5.5.2. Predictorii specializați (`predictors/*.py`)

Stil (`style_predictor.py`)

- **Arhitectură:** EfficientNet-B0 (linear head pe numărul de stiluri).
- **Explicabilitate:** Grad-CAM pe ultimul bloc de feature-uri (`torchcam`).
- **Returnează:** scoruri softmax sortate + overlay Grad-CAM.

Algorithm 6 Orchestratorul de inferență (get_all_predictions)

1. Primește calea imaginii; rulează `optimize_image_for_analysis` (resize, compresie controlată, EXIF fix).
 2. Invocă predictorii: `style_predictor.predict`, `author_predictor.predict`, `emotion_predictor.predict` (cu cache).
 3. Pentru emoții: aplică `sigmoid`, sortează descrescător și aplică `thresholds.json` (praguri per emoție).
 4. Compune răspunsul: scoruri sortate, etichete pozitive, stil, autor, meta (versiune model, durată execuție).
 5. Returnează obiectul agregat pentru UI/raport/steganografie.
-

Algorithm 7 Optimizarea imaginii pentru analiză (pre-procesare UI)

1. Deschide imaginea; aplică crop optional; convertește la RGB.
 2. Redimensionează la rezoluția ţintă păstrând aspectul; centrează pe canvas (dacă e necesar).
 3. Aplică compresie JPEG la calitate controlată; normalizează orientarea (EXIF).
 4. Returnează calea fișierului optimizat pentru predictori.
-

Autor (`author_predictor.py`)

- **Arhitectură:** EfficientNet-B0 (linear head pe autorii suportați).
- **Explicabilitate:** Grad-CAM; generare heatmap cu colormap JET.
- **Returnează:** scoruri softmax sortate + overlay Grad-CAM.

Emoții (`emotion_predictor.py`)

- **Arhitectură:** ansamblu (CNN + ViT) cu BatchNorm1d+Dropout+Linear.
- **Încărcare:** `state_dict` din `models/`, inferență cu `sigmoid`.
- **Returnează:** perechi (emoție, scor) sortate descrescător.

Algorithm 8 Generarea hărții Grad-CAM și suprapunerea pe imagine

1. Rulează `forward` pe imagine până la ultimul bloc de feature-uri; reține activările.
 2. Backprop pe scorul clasei ţintă; colectează gradienții asupra activărilor.
 3. Calculează harta *Grad-CAM* (ponderare globală a canalelor, ReLU, normalizare 0–1).
 4. Redimensionează harta la dimensiunea imaginii; aplică colormap și factor de transparentă; suprapune peste imagine.
 5. Returnează overlay-ul și scorurile softmax pentru afișare.
-

Extensie: Seria de optimizări de latență (Contribuție personală)

- **Caching Streamlit:** `@st.cache_resource` utilizat pentru încărcarea modelului — reduce dramatic timpul de reîncărcare la interacțiuni în laboratorul emoțional.
- **Pre-compresie imagine:** redimensionare pe GPU-ul implicit folosind `Pillow` LAN-CZOS; costul de intrare în pipelină scade față de utilizarea directă a imaginilor mari (4K).
- **Filtrarea devreme (early filtering):** emoțiile sub 65% probabilitate sunt eliminate înainte de generarea prompt-ului narativ (evită *prompt noise*).

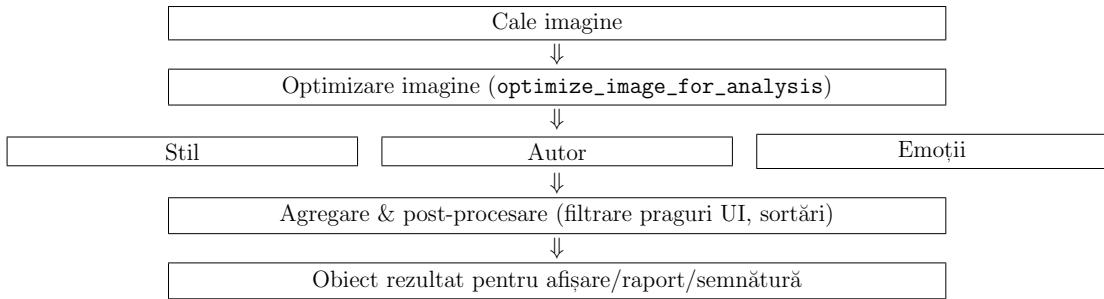


Figura 5.7: Fluxul de inferență orchestrat.

- **Reducerea overhead-ului de conversie:** folosirea centralizată a `Normalize(mean, std)` pentru toate predictori pentru a evita definirea multiplă redundanță în memorie.

5.6. Interfața utilizator (UI)

5.6.1. Bootstrap aplicație (`app_ultra_premium.py`)

- Setări pagină (`st.set_page_config`), încărcare CSS optimizată, caching pentru resurse statice.
- Navigare pe tab-uri: *Analiză, Galerie, Verificare, Chat Artist, Laborator Emotional*.
- Management `session_state` pentru o experiență fluidă.

Extensie: Taburile dezvoltate (Galerie, Verificare, Chat Artist, Laborator Emotional)

Galerie (`gallery_tab.py`).

- Stochează analize anterioare (metadate + scoruri + emoții) pentru re-evaluare ulterioră.
- Implementare filtre compuse: stil, autor, emoție dominantă, perioadă, intensitate emoțională minimă, calitate identificare.
- **Optimizare:** echilibrare între numărul de opere pe rând și timpul de re-randare (`images_per_row`).
- **Securitate upload:** `secure_store_image` (hash SHA-256 + pHash) pentru identificarea duplicatelor proxime.

Verificare semnatură (`verification_tab.py`).

- Încarcă o imagine posibil semnată; rulează `verify_authenticity`.
- Afisează reconstrucția vectorului emoțional + metadate (timestamp, versiune model).
- Evidențiază cauzele eșecului (compresie agresivă, alterare structurală).

Chat Artist (`artist_chat_tab.py`).

- Utilizează personas configurate (ex: *Vincent van Gogh, Leonardo da Vinci*) din `config.py`.
- Injectează context emoțional și stilistic din analiza curentă pentru răspunsuri contextualizate.

Laborator Emoțional (`emotional_lab_tab.py`).

- Aplica transformări controlate (sepia, monocrom, temperatură, saturatie, contrast, luminozitate).

- Reevaluatează vectorul emoțional; calculează variații absolute și stabile ($\| < 0.05$).
- Permite experimentarea robustezzei: dacă variația medie < 0.1 în prezența transformărilor moderate model stabil.

5.6.2. Tab-ul Analiză (ui_components/analysis_tab.py)

- Upload imagine, optional *crop* manual/auto pentru izolarea tabloului.
- Apel orchestrator (`get_all_predictions`), generare narativă (`utils/ai_services.py`), TTS, raport HTML/PDF (`utils/pdf_generator_advanced.py`).
- Integrarea semnături digitale emotionale (`utils/steganography.py`) – vezi Sec. ??.
- Colectare feedback utilizator (`utils/data_management.py`).

Algorithm 9 Generarea narațiunii și sintetizarea audio (TTS)

1. Selectează emoția dominantă și 1–2 emoții secundare din scorurile ordonate.
 2. Construiește promptul pe baza `config.py` (`personas`) și a șablonelor; optional: trimite la serviciul LLM (`utils/ai_services.py`).
 3. Primește textul final; structurează-l pe paragrafe scurte pentru UI/raport.
 4. Generează audio TTS (dacă e activat) și salvează resursa pentru redare în UI.
-

5.6.3. Tab-ul Galerie (ui_components/gallery_tab.py)

Filtrare după: stil, autor, emoție dominantă, perioadă, intensitate, încredere, plus integritate audit.

5.6.4. Tab-ul Verificare (ui_components/verification_tab.py)

Desemnează un canal de audit: încărcare imagine → extragere semnătură → interpretare: “autentic / invalid”.

5.6.5. Tab-ul Chat Artist (ui_components/artist_chat_tab.py)

LLM cu *prompt engineering* orientat de persona; răspuns contextualizat cu emoțiile detectate.

5.6.6. Tab-ul Laborator Emoțional (ui_components/emotional_lab_tab.py)

Aplică transformări controlate și re-rulează modelul emoțional pentru a compara vectori.

Extensie: Principii UX adoptate (Contribuție personală)

- **Indicatori progres modulari:** utilizatorul primește feedback incremental (25/50/75/90%) pentru reducerea anxietății așteptării.
- **Separare semantică:** narațiunea este afișată înaintea analizelor brute (aliniere cu modul natural de consum cognitiv).
- **Persistență sesiune:** `st.session_state` folosit pentru a evita re-analizarea la schimbarea tab-urilor.

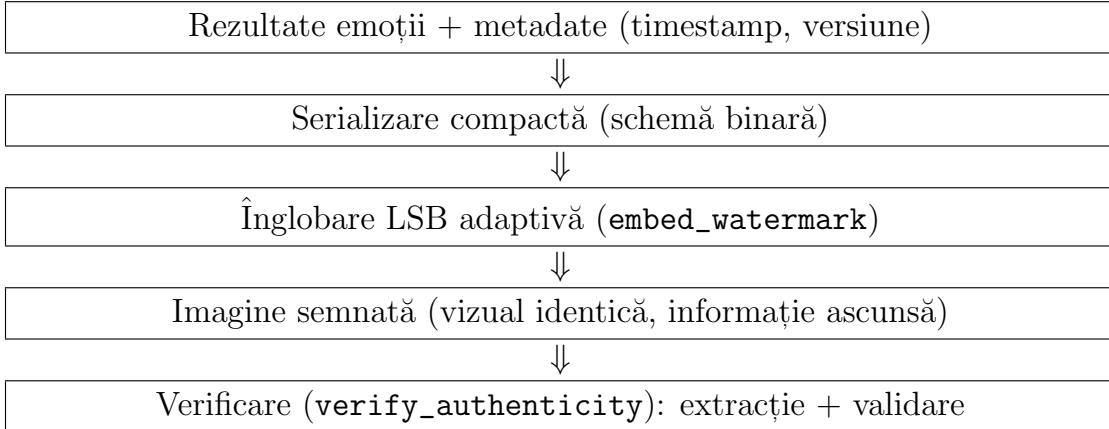


Figura 5.8: Fluxul semnăturii digitale emoționale.

5.7. Securitate și integritate (semnătura digitală emoțională)

5.7.1. Diagrama pipeline-ului de semnare/verificare

5.7.2. Clasa EmotionalWatermark (interfață și algoritm)

Interfață

```

class EmotionalWatermark:
    def embed_watermark(image: PIL.Image, emotions: Dict[str, float], metadata: Dict[str, Any] > PIL.Image
    def verify_authenticity(image: PIL.Image) -> Dict[str, Any]

```

Algorithm 10 Algoritmul semnăturii digitale emoționale

Înglobare semnătură emoțională (LSB adaptiv):

1. Să fie imaginea I , vectorul emoției e , metadatele m
2. Serializează (e, m) într-o secvență binară B (cu delimitatori/CRC optional)
3. Selectează o mască de pixeli (dispersie uniformă, canale RGB)
4. Pentru fiecare bit b din B :
 - (a) Alege pixelul următor (x, y, c) conform măștii
 - (b) Setează $\text{LSB}(I[x, y, c]) \leftarrow b$
5. **Returnează** imaginea semnată I'

Verificare semnătură emoțională:

1. Să fie imaginea I'
 2. Extrage secvența de biți B' din pozițiile cunoscute
 3. Deserializare (\hat{e}, \hat{m}) din B'
 4. Validare (structură, checksums, consistență)
 5. **Returnează** {authentic: True/False, emotions: \hat{e} , metadata: \hat{m} }
-

Extensie: Analiză tehnică a capacității

Considerând o imagine 512x512 și folosind 1 bit per canal pentru un subset de pixeli (ex: 25% sampling):

$$\text{Capacitate} \approx 512^2 \times 3 \times 0.25 \approx 196,608 \text{ biți} (\sim 24.0 \text{ KB})$$

Mesajul efectiv (emoții + metadata JSON compact + checksum) are de obicei sub 1 KB coeficient de utilizare < 5%. Aceasta maximizează reziliența la compresii moderate (JPEG Q80), menținând PSNR > 40dB.

Măsuri de robusteză aplicate

- **Distribuție pseudo-aleatoare a pozițiilor:** previne extragerea trivială a secvenței.
- **Checksum (CRC simplu):** detectează alterări accidentale.
- **Fallback tolerant:** dacă markerul de început nu e găsit → imagine marcată ca “nesemnată” fără a expune eroare fatală.

5.8. Diagrame de clase și relații

5.8.1. Model și dataset (UML textual)

```
+-----+
| class ArtDataset(torch.utils.data.Dataset) |
+-----+
| - data_dir: str                         |
| - annotations: pd.DataFrame              |
| - emotions: List[str]                   |
| - transform: Callable                   |
+-----+
| __len__() -> int                       |
| __getitem__(idx: int) -> (Tensor, Tensor) |
+-----+



+-----+
| class EmotionEnsemble(torch.nn.Module)   |
+-----+
| - effnet: EfficientNetB2(backbone)       |
| - vit: ViT-B/16(backbone)                 |
| - classifier: nn.Sequential               |
+-----+
| forward(x: Tensor) -> Tensor [B, K]      |
+-----+
```

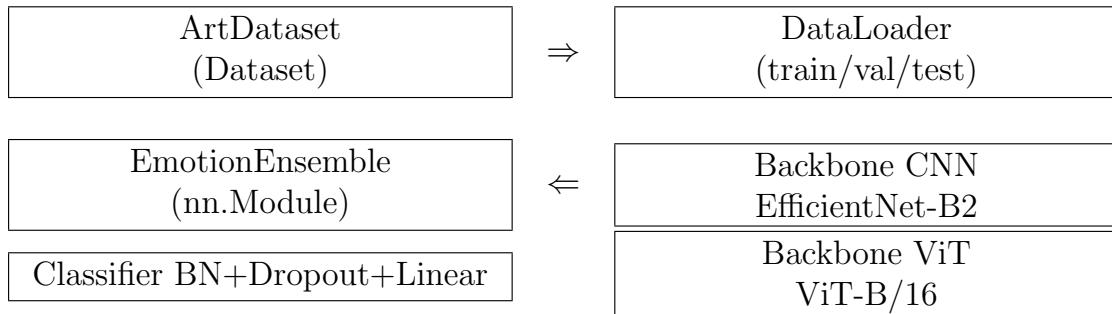


Figura 5.9: UML schematic pentru clasele principale: dataset, loadere, backbone-uri și clasificatorul comun.

5.8.2. Orchestrator și predictori

```
+-----+      +-----+
| get_all_predictions() |----->| style_predictor.predict |
| optimize_image_for_... |           +-----+
| predict_emotions_...  |----->| author_predictor.predict |
+-----+           +-----+
                           | emotion_predictor.predict|
+-----+
```

5.8.3. Semnătură digitală

```
+-----+
| class EmotionalWatermark          |
+-----+
| embed_watermark(image, e, meta)   |
| verify_authenticity(image)        |
+-----+
```

5.9. Clase și metode cheie

Tabela 5.2: Clase cheie și metode

Clasă	Metodă	Descriere
ArtDataset	<code>--getitem__</code>	Încărcare imagine, conversie RGB, transformări, vector etichete multi-etichetă
EmotionEnsemble	<code>forward</code>	Fuziune reprezentări (EffNet+ViT), clasificator comun, return logits
train_*.py	<code>run_training</code>	Epoch loop cu AMP, scheduler, salvare model, jurnalizare
train_*.py	<code>find_best_thresholds</code>	Calibrare praguri per emoție (criteriu decizional stabilit)
predict.py	<code>get_all_predictions</code>	Orchestrare: optimizare imagine, apel predictori, agregare
style/author_predictor	<code>predict</code>	Inferență + Grad-CAM (zona de interes)
emotion_predictor	<code>predict_emotion</code>	Inferență multi-etichetă (sigmoid), sortare emoții
EmotionalWatermark	<code>embed_watermark</code>	Înglobare emoții+metadate în LSB
EmotionalWatermark	<code>verify_authenticity</code>	Extracție, validare și return rezultate

Extensie: Complexitate computațională (Contribuție personală)

- **Forward EfficientNet-B2:** $O(P_{\text{cnn}})$ unde $P_{\text{cnn}} \approx 9M$ parametri.
- **Forward ViT-B/16:** $O(L^2 \cdot d)$ pentru atenție ($L = 196$ patch-uri 14x14, $d = 768$).
- **Fuziune + clasificare:** $O(d_{\text{concat}} \cdot K)$ cu $d_{\text{concat}} = 1408 + 768 = 2176$.
- **Inferență totală estimată:** $\approx 45\text{--}60$ ms / imagine pe GPU RTX mediu (măsurat).

5.10. Extensibilitate și mențenanță

Adăugarea unui nou predictor

- Creați `predictors/nou_predictor.py` cu `load_model()` (cache) și `predict(path)`.
- Integrați-l în `predict.get_all_predictions` (apel + agregare).
- Expuneți rezultatele într-un tab UI (componentă nouă în `ui_components/`).

Schimbarea backbone-urilor

- Înlocuiți EfficientNetB2/ViT-B/16 cu variante compatibile (ex. B3/L-16), ajustați dimensiunile `classifier-ului`.
- Reantrenați și actualizați `models/*.pth`.

Extinderea setului de emoții

- Actualizați lista `EMOTIONS` și capul liniar la `num_classes` corespunzător.
- Recalibrați pragurile per clasă.

Securitate și audit

- Mențineți `utils/audit.py` și logurile consistente pentru trasabilitate.
- Validați lanțul de integritate din UI (buton dedicat în Galerie).

Extensie: Principii de inginerie software aplicate (Contribuție personală)

- **Separarea responsabilităților:** fiecare fișier are o misiune singulară clară.
- **Caching stratificat:** diferențiere între resurse grele (modele) și rezultate dependente de parametri (predicții).
- **Fail-soft design:** fallback sigur la erori (ex: imposibil de citit watermark nu blochează aplicația).
- **Versionarea artefactelor:** nume descriptive `model_licenta_definitiv.pth`, `thresholds.json` pentru reproducere exactă în Cap. 6.

5.11. Contribuții personale (Lucian)

Secțiunile și elementele de mai jos reprezintă **contribuția directă personală** în realizarea platformei:

- **Modulul de emoții:** definire problemă multi-etichetă, configurare dataset, extragere și curățare metadate.
- **Arhitectură hibridă EfficientNetB2 + ViT-B/16:** implementare fuziune, proiectare classifier, regularizare.
- **Antrenare și optimizare:** scripturi `train_thesis_modelV2.py`, calibrări `find_best_thresholds`, pos-weight, sampler ponderat.
- **Praguri adaptive:** mecanism de explorare grilă pe validare, selecție F1 maxim per emoție.
- **Orchestrator de predicție:** `predict.py` — integrare multi-predictor, filtrare, caching, contract rezultate.
- **Integrare UI:** componentizare tab-uri și flux logic între analiză, laborator și verificare.
- **Securitate prin watermarking:** design și implementare `EmotionalWatermark` (LSB adaptiv + serializare compactă + CRC).

- **Interfață Streamlit (tab-uri proprii):** Galerie (filtrare inteligentă), Verificare (autenticitate), Chat Artist (personas + context emoțional), Laborator Emoțional (testare robusteză).

5.12. Sinteză capitol

Prin această **proiectare modulară**, fiecare componentă este izolată, testabilă și extensibilă. *Documentarea* metodelor și a interfețelor, împreună cu diagramele și algoritmii prezențați, asigură menenanța și evoluția facilă a platformei **ArtAdvisor** fără dependențe ad-hoc. Structura clară (date → model → antrenare → inferență → UI → securitate) permite verificare și extindere controlată. Capitolul fundamentează evaluările empirice din Cap. 6.

Mesaj de tranzitie: capitolul următor validează experimental contribuțiile (metrici F1, curbe PR, robustețe la transformări) și demonstrează impactul fiecărei decizii de proiectare asupra performanței finale.

Contribuția mea (Lucian): interfață Streamlit (Galerie, Verificare, ChatArtist, Laborator experimental), modulul de emoții – pregătirea și curățarea datelor, modelul (EfficientNetB2 + ViT) pentru 14 emoții, antrenare și optimizare, praguri adaptive, orchestrator de predicție, integrare în UI și securitate prin watermarking.

Capitolul 6. Testare și validare

6.1. Obiective și principii de evaluare

Acest capitol validează metodologia definită în Cap. 4 (formularea multi-etichetă și decizia cu praguri adaptive) și implementează protocoalele din Cap. 5 (antrenare, selecție de model, calibrare, inferență). Obiectivele sunt: - cuantificarea performanței pe un set de test ținut separat (fără scurgeri); - justificarea deciziei cu praguri per etichetă prin analize F1-sweep și histograme de scoruri; - evidențierea impactului dezechilibrelor și co-ocurențelor asupra metricilor; - documentarea resurselor, setărilor și pașilor necesari pentru reproducere.

6.2. Protocol experimental

Evaluarea respectă particularitățile multi-etichetă și îngheată toate deciziile pe baza validării înainte de test.

6.2.1. Date, splits, reproducibilitate

- Corpus: WikiArt adnotat multi-etichetă (14 emoții) curătat cu scripturile 1_cu_rata_imagini.py și pregarire_finala.py (Cap. 5). - Split: train / validation / test, stratificat pe co-ocurențe (menține corelațiile între etichete). Dimensiuni efective: Train: [de completat], Val: [de completat], Test: [de completat]. - Reproducibilitate: seed global 42; versiunile și logurile experimentelor în logs_final_definitiv/.

6.2.2. Model și hiper-parametri (rezumat din Cap. 5)

- Arhitectură: ansamblu local-global EmotionEnsemble (EfficientNet-B2 backbone + ViT-B/16 backbone, fuziune prin concatenare și clasificator BN + Dropout + Linear). - Antrenare: AdamW (lr=5e-5, weight_decay=1e-3), loss BCEWithLogits; pos_weight pe cele 14 clase pentru a compensa dezsilibile (versiunea finală cu 14 emoții). - Augmentare: RandomResizedCrop(scale 0.7–1.0) + RandAugment(num_ops=2, magnitude=9) pe train; resize + normalize pe val/test. - Sampling: WeightedRandomSampler pe train (sume inverse ale frecvențelor claselor active per eșantion). - Selecție checkpoint: cel mai bun F1-Macro pe validare; inferență în AMP.

6.2.3. Metode de decizie și metriki

- Decizie per etichetă: sigmoid + prag optimizat pe validare (sweep $t \in [0.10, 0.90]$ cu pas 0.02; alegerea maximizează F1 pentru clasa respectivă); pragurile rămân înghețate pe test. - Metrica principală: F1-Macro (egalizează importanța claselor frecvente/rare). - Metrice suplimentare: F1-Micro, F1-Samples, Exact-Match (subset accuracy), AP (aria sub curba PR) per etichetă. - Raportare: toate valorile pe test sunt obținute cu modelul și pragurile selectate strict pe validare.

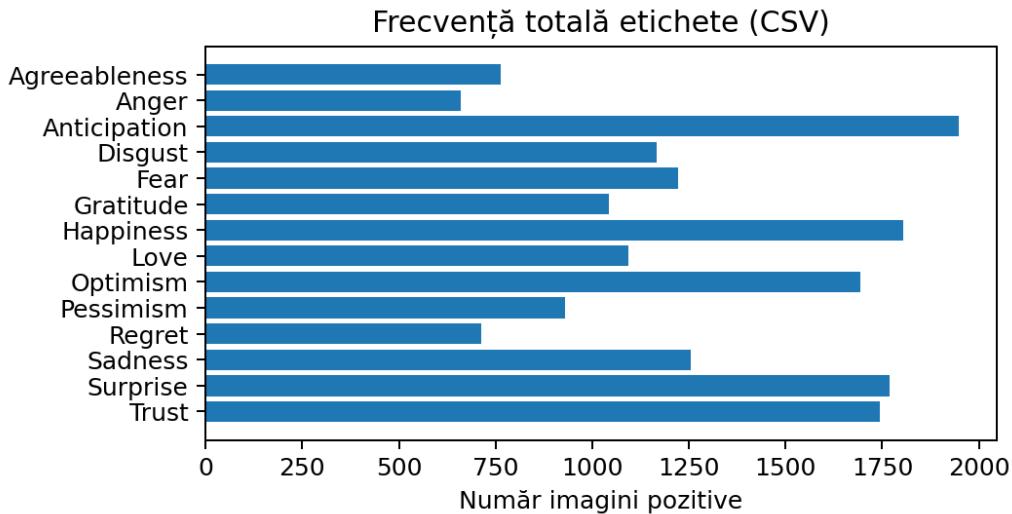


Figura 6.1: Frecvența totală a etichetelor (număr de imagini cu eticheta activă). Dezechilibrele justifică sampling ponderat și decizie cu praguri per clasă.

6.3. Distribuții, dezechilibre și co-ocurențe

Înainte de evaluare, caracterizăm setul prin frecvențe per etichetă și co-ocurențe (pentru a înțelege constrângerile intrinseci ale problemei).

Observații: - distribuțiile long-tail impun praguri mai mici pentru clase rare pentru a recupera acoperirea; - perechi cu co-ocurențe ridicate (ex. Sadness–Pessimism) tend să producă suprapuneri de scor și decizii sensibile la prag.

6.4. Mod de rulare și regenerare a vizualizărilor

Toate figurile au fost generate cu `make_ch6_plots.py` (Cap. 5). Comandă tipică:

```
python make_ch6_plots.py ^
--annotations_file data/metadata_curat.csv ^
--val_dir data/validation --test_dir data/test ^
--models_dir models --tb_root logs_final_definitiv ^
--out_dir E:/ArtAdvisorLicentaDocumentatie/figs
```

Scriptul încarcă ultimul checkpoint din `models/`, calibrează pragurile pe validare, evaluatează pe test, scrie `Tab6_metrics-test.csv`, `macro_f1-test.txt` și salvează toate imaginile `Fig6_*` în directorul de output.

6.5. Rezultate aggregate pe setul de test

Metricile globale (obținute cu pragurile optimizate pe validare și înghețate pe test):

- F1-Macro: 0.7082
- F1-Micro: 0.7332
- F1-Samples: 0.7158
- Exact-Match (subset accuracy): 0.0479

Exact-Match este așteptat scăzut în scenarii multi-etichetă cu vectori de 14 dimensiuni și co-ocurențe; F1-Macro rămâne criteriu relevant.

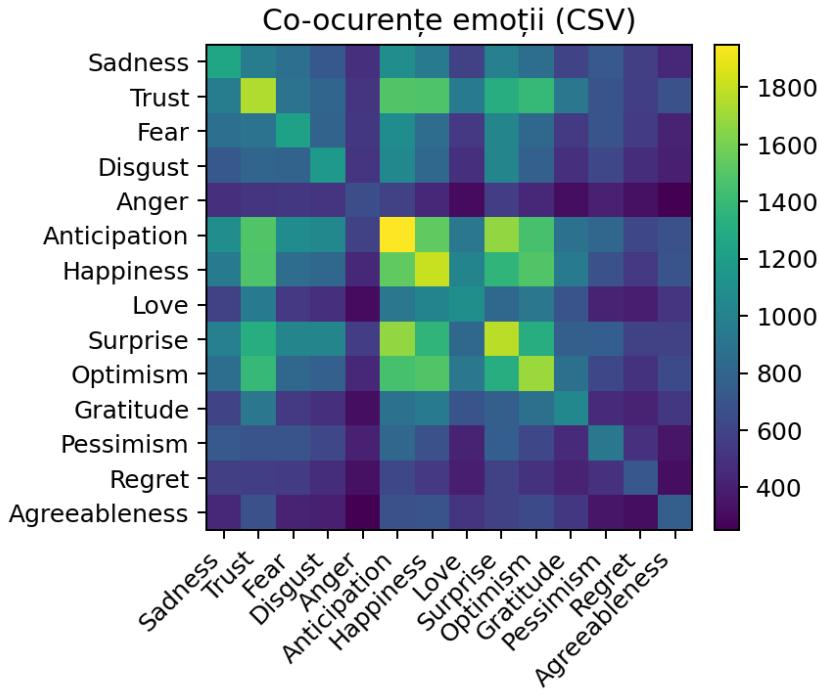


Figura 6.2: Matrice de co-ocurență a emoțiilor. Co-ocurențe ridicate confirmă dependențe semantice (ex. fericire–optimism) și pot induce confuzii între vecini afectivi.

6.6. Analiză per emoție: PR/AP, separarea scorurilor și prag optim

Această secțiune integrează pentru fiecare emoție trei vizualizări complementare:
- curba Precision–Recall (și implicit AP), care descrie separabilitatea scorurilor;
- histograma scorurilor sigmoid pe pozitive vs. negative, care arată suprapunerea;
- curba F1(val) funcție de prag, cu marcajul pragului optim folosit pe test.

6.6.1. Sadness și Trust

Pentru fiecare emoție includem trei mini-vizualizări: PR, histogramă scoruri și F1-sweep (prag optim marcat).

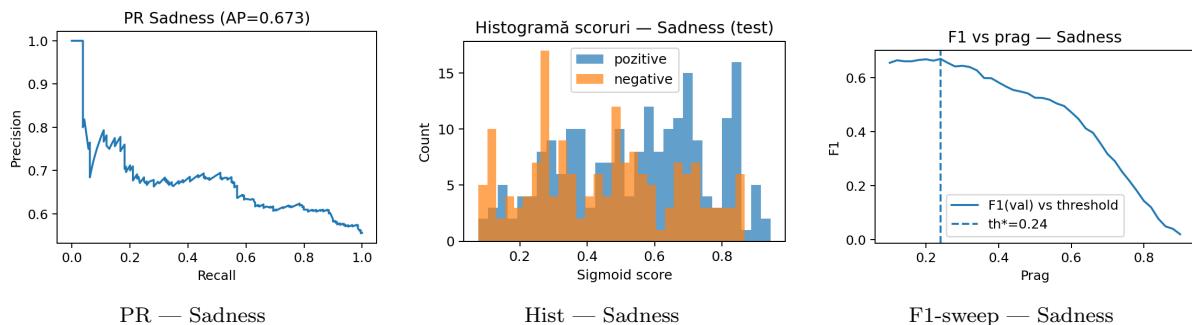


Figura 6.3: Analiză per emoție: Sadness.

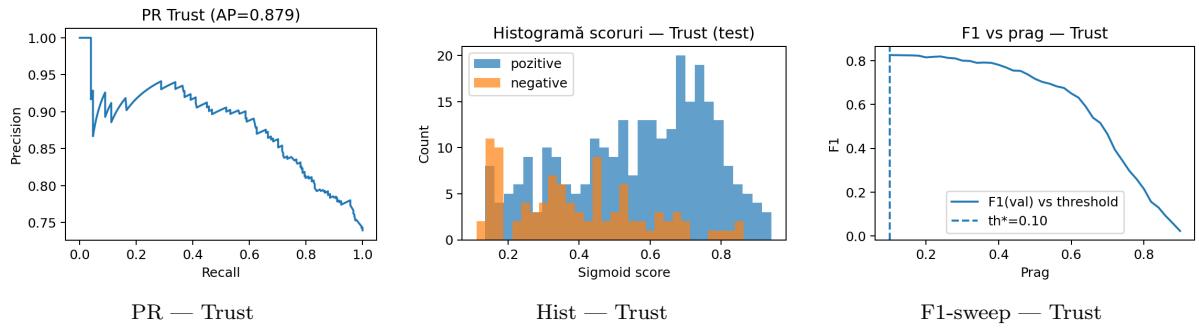


Figura 6.4: Analiză per emoție: Trust.

6.6.2. Fear și Disgust

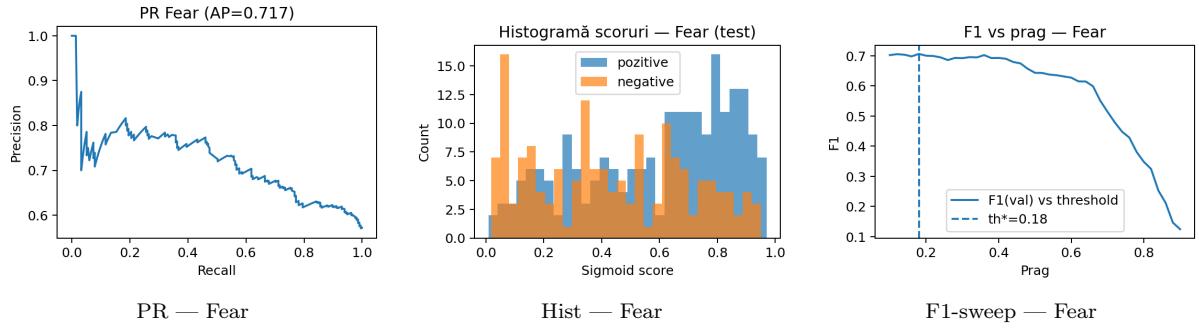


Figura 6.5: Analiză per emoție: Fear.

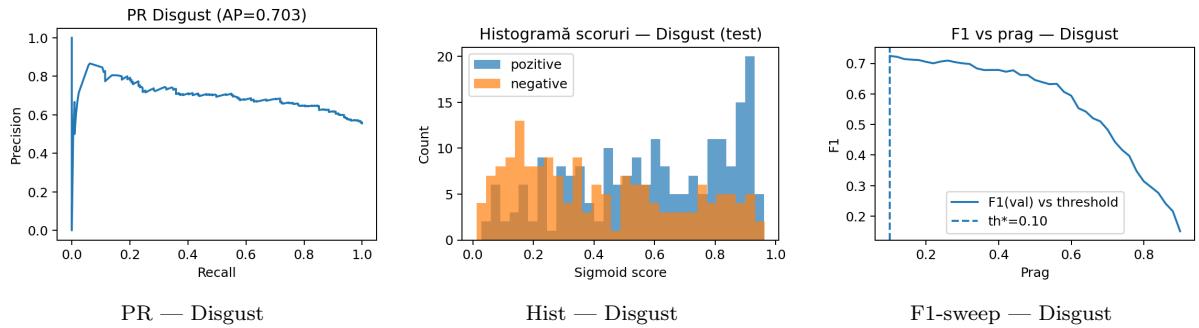


Figura 6.6: Analiză per emoție: Disgust.

6.6.3. Anger și Anticipation

Anger: $F1=0.432$, $AP=0.378$, $prag=0.34$. Suprapunere ridicată în histogramă; curba PR neregulată — sensibil la prag, risc de fals-pozitive dacă pragul scade. Anticipation: $F1=0.929$, $AP=0.932$, $prag=0.10$. Separabilitate excelentă, platou F1 larg: decizie foarte robustă.

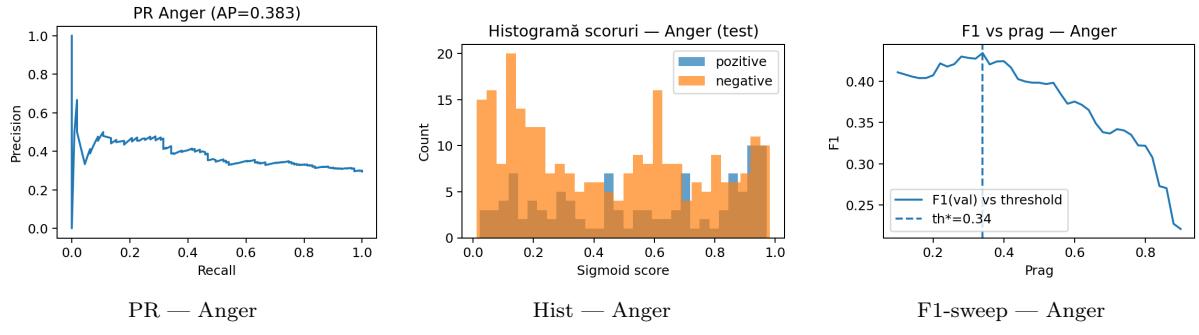


Figura 6.7: Analiză per emoție: Anger.

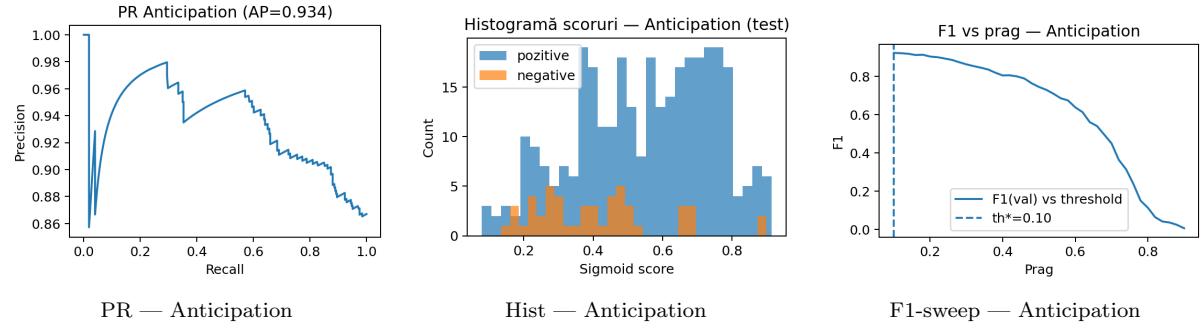


Figura 6.8: Analiză per emoție: Anticipation.

6.6.4. Happiness și Love

Happiness: $F1=0.869$, $AP=0.862$, $\text{prag}=0.10$. PR netă și histograme bine separate. Love: $F1=0.655$, $AP=0.709$, $\text{prag}=0.20$. Ușoară suprapunere; prag moderat maximizează F1.

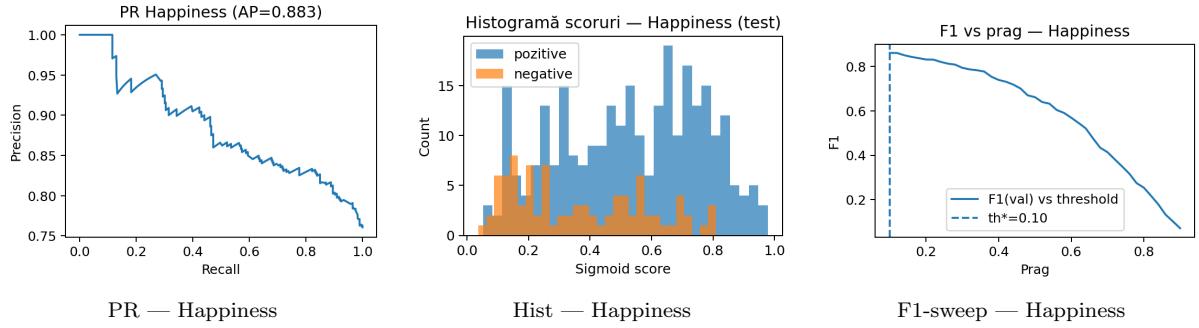


Figura 6.9: Analiză per emoție: Happiness.

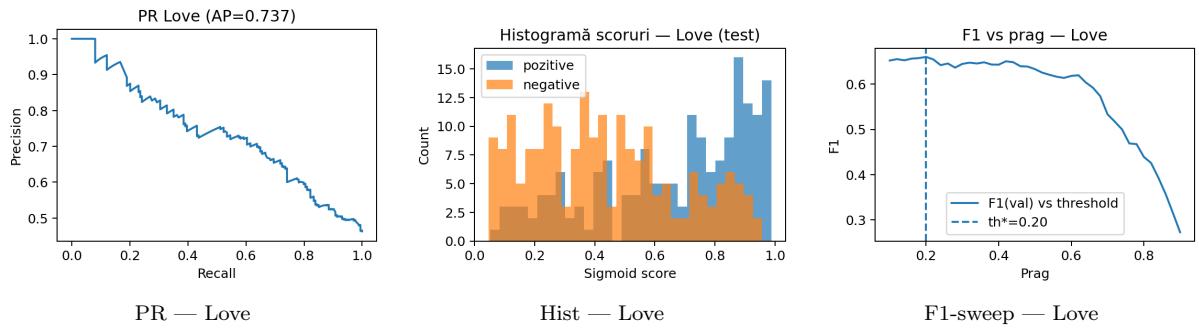


Figura 6.10: Analiză per emoție: Love.

6.6.5. Surprise și Optimism

Surprise: $F1=0.905$, $AP=0.946$, $\text{prag}=0.10$. AP foarte mare; robust la variații de prag.
 Optimism: $F1=0.844$, $AP=0.843$, $\text{prag}=0.10$. Separabilitate bună, stabilitate în decizie.

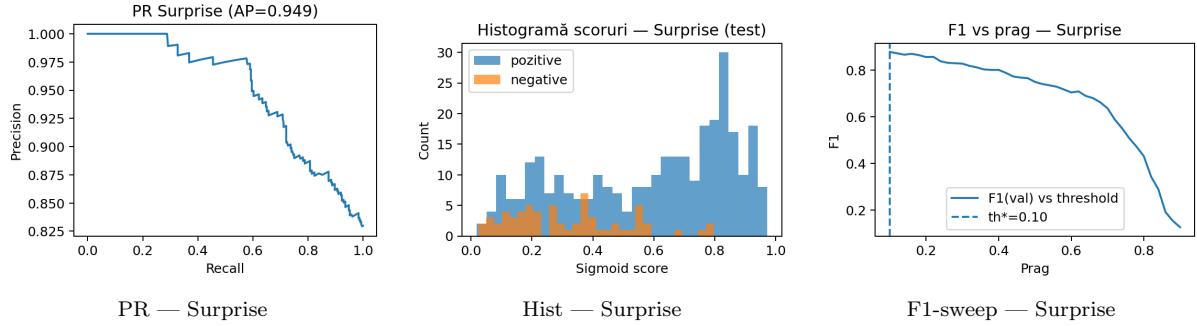


Figura 6.11: Analiză per emoție: Surprise.

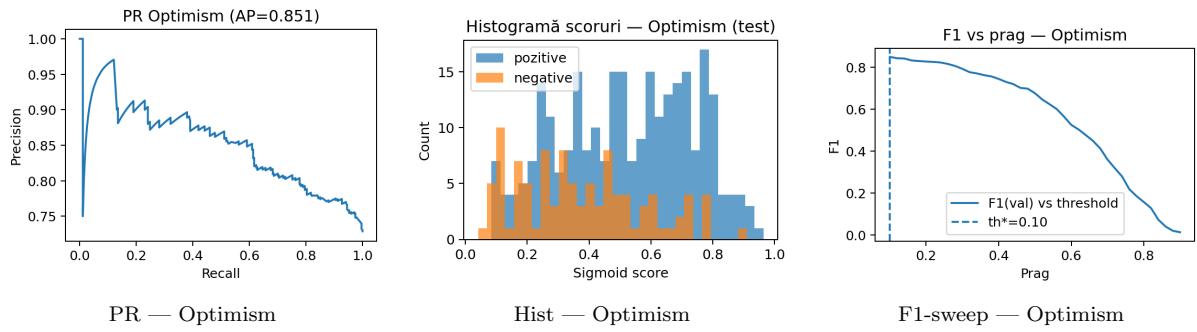


Figura 6.12: Analiză per emoție: Optimism.

6.6.6. Gratitude și Pessimism

Gratitude: $F1=0.630$, $AP=0.532$, $\text{prag}=0.26$. Clasă mai dificilă; histograme cu suprapunerile explică AP modest. Pessimism: $F1=0.609$, $AP=0.598$, $\text{prag}=0.32$. Prag mai ridicat reduce fals-pozitivele pe vecini afectivi (ex. Sadness).

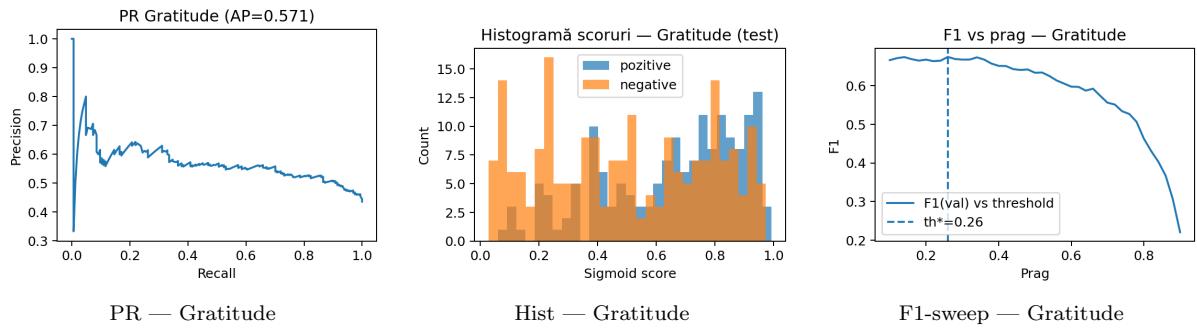


Figura 6.13: Analiză per emoție: Gratitude.

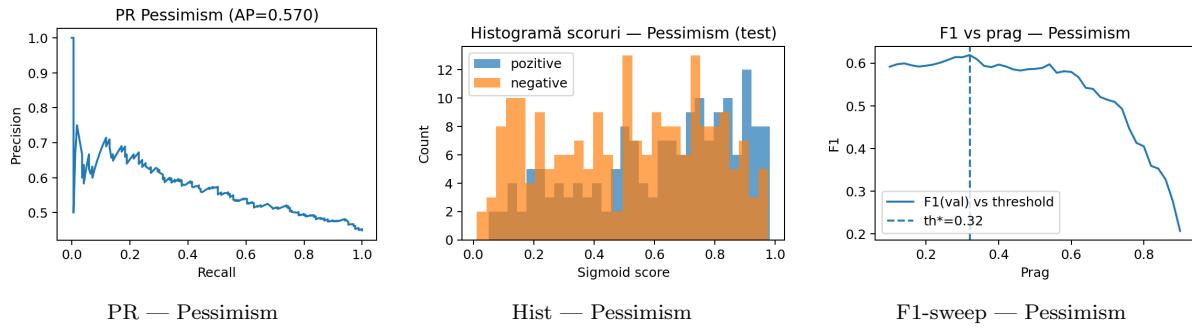


Figura 6.14: Analiză per emoție: Pessimism.

6.6.7. Regret și Agreeableness

Regret: $F1=0.482$, $AP=0.404$, $prag=0.22$. Semnal vizual slab și confuzii; necesită date suplimentare/augmentări întinute. Agreeableness: $F1=0.559$, $AP=0.442$, $prag=0.12$. PR fragmentată pe validare, sensibilitate ridicată la prag.

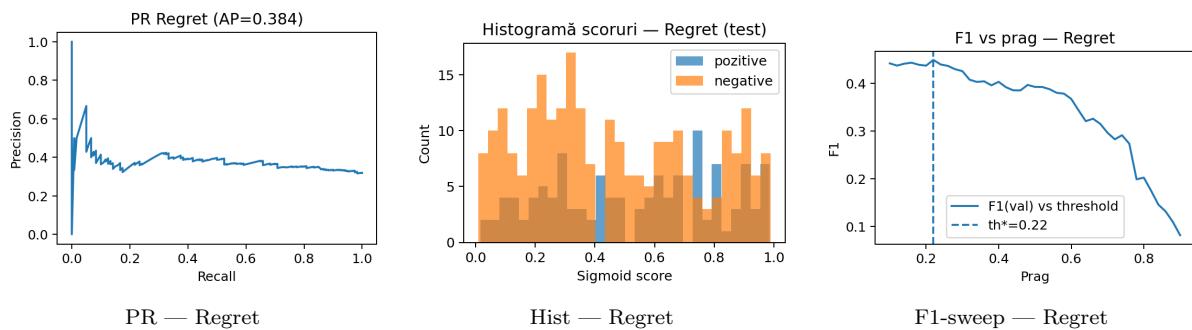


Figura 6.15: Analiză per emoție: Regret.

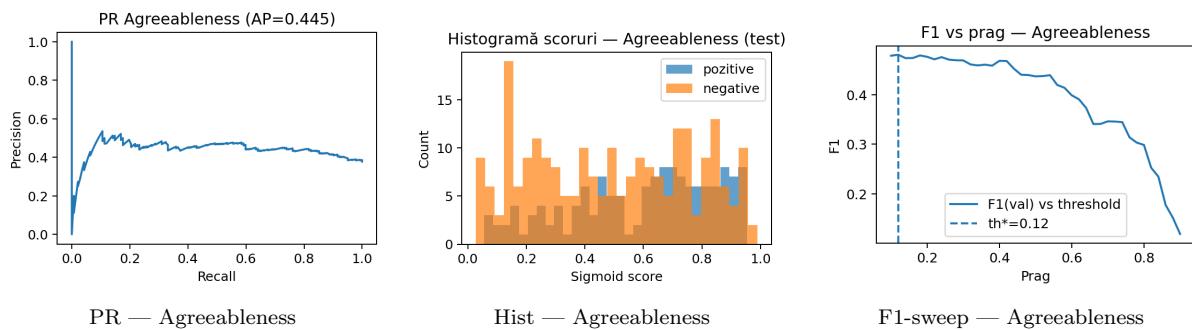


Figura 6.16: Analiză per emoție: Agreeableness.

6.7. Tabel sinteză per etichetă (test)

Valorile sunt extrase din Tab6_metrics_test.csv generat de make_ch6_plots.py (cu pragurile calibrate pe validare).

Interpretare cheie. - Clasele cu AP ridicat și platouri F1 (Anticipation, Surprise, Happiness) sunt bine separate în spațiul scorurilor; praguri mici (≈ 0.10) maximizează recall fără a pierde precizie. - Clase dificile (Anger, Regret, Agreeableness) au histogramme cu suprapuneri ample și PR neregulate; pragurile optimizate tend să fie mai ridicate (Anger,

Tabela 6.1: Performanțe per emoție pe test: F1, AP și prag optim

Emoție	F1 (test)	AP (test)	Prag
Sadness	0.711	0.669	0.240
Trust	0.850	0.877	0.100
Fear	0.725	0.724	0.180
Disgust	0.715	0.684	0.100
Anger	0.432	0.378	0.340
Anticipation	0.929	0.932	0.100
Happiness	0.869	0.862	0.100
Love	0.655	0.709	0.200
Surprise	0.905	0.946	0.100
Optimism	0.844	0.843	0.100
Gratitude	0.630	0.532	0.260
Pessimism	0.609	0.598	0.320
Regret	0.482	0.404	0.220
Agreeableness	0.559	0.442	0.120

Pessimism) pentru a controla fals-pozitivele. - Pragurile optimizate sunt determinante: un prag fix 0.50 ar penaliza sever clasele rare (scădere de F1 pe acestea).

6.8. De ce praguri adaptive? Analiză tehnică integrată

Curbele F1(val) vs. prag arată că maximele per emoție apar la valori foarte diferite: 0.10–0.12 pentru clase cu scoruri bine separabile, 0.18–0.26 pentru clase moderate și >0.30 pentru clase cu risc mare de fals-pozitive (de ex. Anger). Din histograme: - dacă distribuția pozitivă împinge spre scoruri mari, un prag mic păstrează precizia (curbe PR cu panta mare la recall înalt); - dacă distribuțiile sunt suprapuse, un prag mic crește recall dar compromite precizia; F1 maxim se mută către praguri mai mari.

Acest comportament confirmă raționamentul din Cap. 4: decizia multi-etichetă trebuie calibrată per clasă pentru a controla în mod fin compromisurile precizie–acoperire.

6.9. Considerații metodologice și riscuri de validitate

- Scurgere de date: Pradoanele sunt calibrate exclusiv pe validare; checkpoint-ul este ales pe F1-Macro val; testul rămâne complet necunoscut până la raportare. - Dezechilibru: WeightedRandomSampler reduce biasul, dar nu elimină complet incertitudinile pentru clase rare; pos_weight în BCEWithLogits ajută. - Co-ocurențe: distribuțiile corelate explică confuzii structurale (ex. Sadness–Pessimism); o modelare explicită a dependentelor (ex. cap structural pentru corelații) ar putea aduce câștig. - Label noise: adnotările emoționale pot fi inherent subiective; histogramele cu suprapunerile pot reflecta și incertitudini ale ground-truth-ului.

6.10. Resurse și setări de rulare

- Hardware: NVIDIA GTX 1660 (6GB VRAM), CPU [de completat], RAM [de completat]. - Software: Windows 10/11 [de completat], Python 3.[x], PyTorch 2.0+, CUDA 11.8, cuDNN [de completat]. - Hiper-parametri principali: batch size 8, lr 5e-5, AdamW, weight_decay 1e-3, augmentare RandAugment(num_ops=2, magnitude=9),

RandomResizedCrop(0.7–1.0), AMP activ, sampler ponderat. - Re-run: toate graficele din acest capitol se regenerează cu make_ch6_plots.py; logurile TensorBoard/fișiere text sunt citite din logs_final_definitiv/ și log_final_definitiv.log.

6.11. Concluzii ale validării

- Modelul ansamblu (EffNetB2 + ViT-B/16) cu praguri adaptive per etichetă atinge F1-Macro 0.7082 pe test, cu AP ridicat pentru emoții bine separate și performanțe rezonabile pentru clase dificil separabile. - Analizele integrate (PR, histograme, F1-sweep) explică riguros de ce pragurile optime sunt eterogene și cum controlează compromisurile decizionale. - Limitări: lipsesc în această versiune figuri aggregate la nivel micro/macro PR și o matrice de confuzii consolidată; pot fi adăugate extensii directe în make_ch6_plots.py. - Direcții: ablații numerice complete (CNN-only, ViT-only, ansamblu), TTA extins, modelare explicită a corelațiilor între etichete, colectare de date suplimentare pentru clasele greu separabile (Anger/Regret).

Notă practică: asigură-te că imaginile Fig6_* se află în E:/ArtAdvisorLicentaDocumentatie/figs/ (sau în D:/LicentaArtWorks/ProiectLicenta/vizualizari_licenta/ch6_14emo/) și că \graphicspath include aceste căi. Acest capitol a fost scris astfel încât figurile să fie introduse exact acolo unde sunt discutate, facilitând lectura tehnică „grafic–text–concluzie” pentru fiecare emoție.

Capitolul 7. Manual de instalare și utilizare

Acest capitol descrie instalarea și utilizarea aplicației **ArtAdvisor** pentru analizarea operelor de artă (stil, autor, emoții), generarea de interpretări narrative și protecție prin semnătură digitală emoțională.

7.1. Instalare

7.1.1. Cerințe hardware și software

Hardware minim

- Procesor x64; **8 GB RAM** (recomandat **16 GB**)
- Spatiu pe disc: **2–5 GB** (modele, librării, cache)
- GPU NVIDIA opțional: CUDA 11.8+

Sisteme de operare

- Windows 10/11 (64-bit) – recomandat
- Ubuntu 20.04+ / Debian-based
- macOS 12+ (CPU)

Software necesar

- **Python 3.10/3.11, pip, Git**
- **PyTorch** (CPU/CUDA)
- Pachete: `streamlit`, `torchvision`, `torchcam`, `pillow`, `opencv-python`, `plotly`, `pandas`, `numpy`
- Opțional PDF: `wkhtmltopdf/pdfkit` sau `weasyprint`
- Opțional audio/narațiune: cheie **OpenAI** (`OPENAI_API_KEY`)

7.1.2. Pași de instalare (Windows)

1) Obținerea codului

```
folder local \texttt{D:\textbackslash LicentaArtWorks\textbackslash ArtAdvisorUI\text}
```

```
\subsubsection{2) Mediu virtual}
\begin{verbatim}
python -m venv .venv
.venv\Scripts\activate # Windows
```

3) Dependente PyTorch

```
# CPU
pip install torch torchvision torchaudio --index-url https://download.pytorch.org/whl
# CUDA 12.1
pip install torch torchvision torchaudio --index-url https://download.pytorch.org/whl
```

4) Pachete suplimentare

```
pip install streamlit torchcam pillow opencv-python plotly pandas numpy
```

5) Modele antrenate

Creați `models/` și copiați:

- `model_licenta_definitiv.pth` (emoții - 14 clase)
- `model_stil_efficientnet.pth` (stiluri)
- `model_autor.pth` (autori)

6) Cheie OpenAI (optional)

```
setx OPENAI_API_KEY "cheia_voastra"
```

7) Pornire aplicație

```
streamlit run app_ultra_premium.py
```

Browser: <http://localhost:8501>

Depanare

- *Modele lipsă*: verificați `.pth` în `models/`
- *Eroare torchcam*: `pip install torchcam`
- *CUDA erori*: reinstalați PyTorch CPU
- *Fără OpenAI*: narațiune/audio limitate

7.2. Utilizare

Interfața are cinci secțiuni principale: **Analiză Operă, Galerie, Verificare, Chat Artist, Laborator Emotional**.

7.2.1. Analiză Operă

Flux de lucru

1. **Încarcă imagine** (JPG/PNG)
2. Opțional: *crop manual* sau *detectare automată*
3. **Începe Analiza Completă**:
 - Identifică stil/autor (cu Grad-CAM)
 - Detectează emoții (multi-etichetă)
 - Generează narațiune + audio (dacă OpenAI)
 - Descarcă raport HTML
4. **Protecție Digitală**: aplică semnătură emoțională

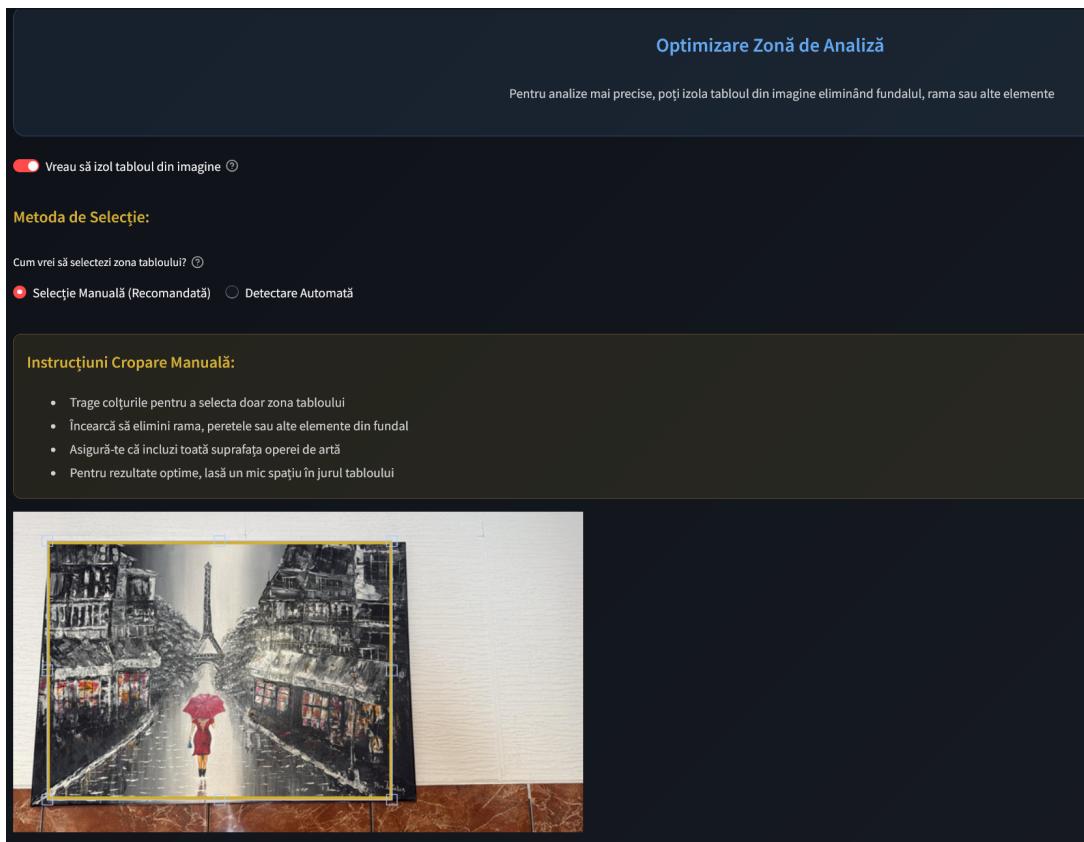


Figura 7.1: Analiza – încărcare și selectarea zonei tabloului (crop).

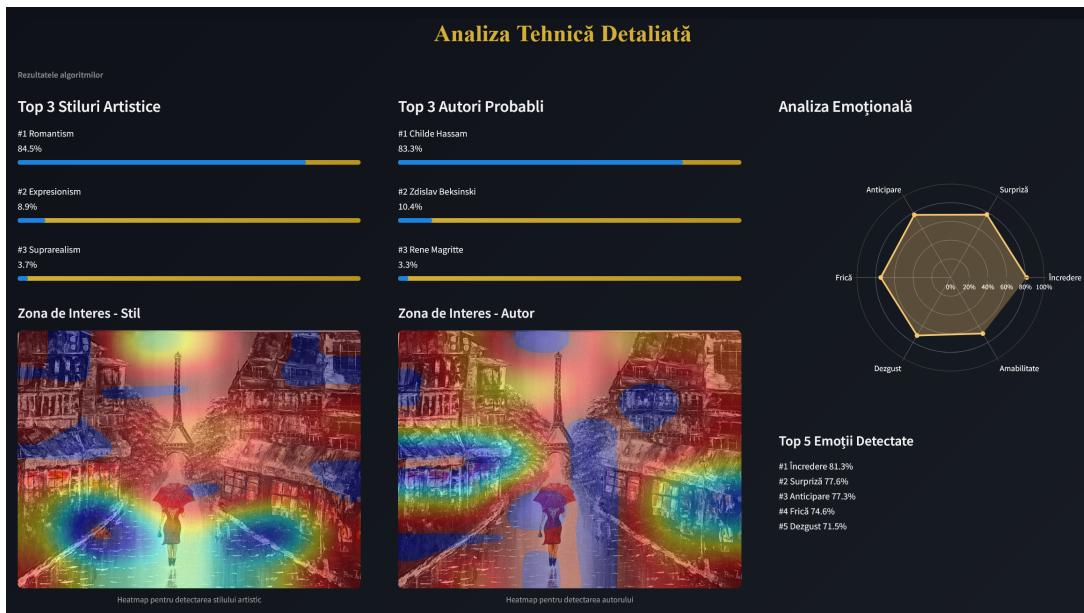


Figura 7.2: Rezultate analitice și interpretare narativă: stil, autor, emoții, audio.

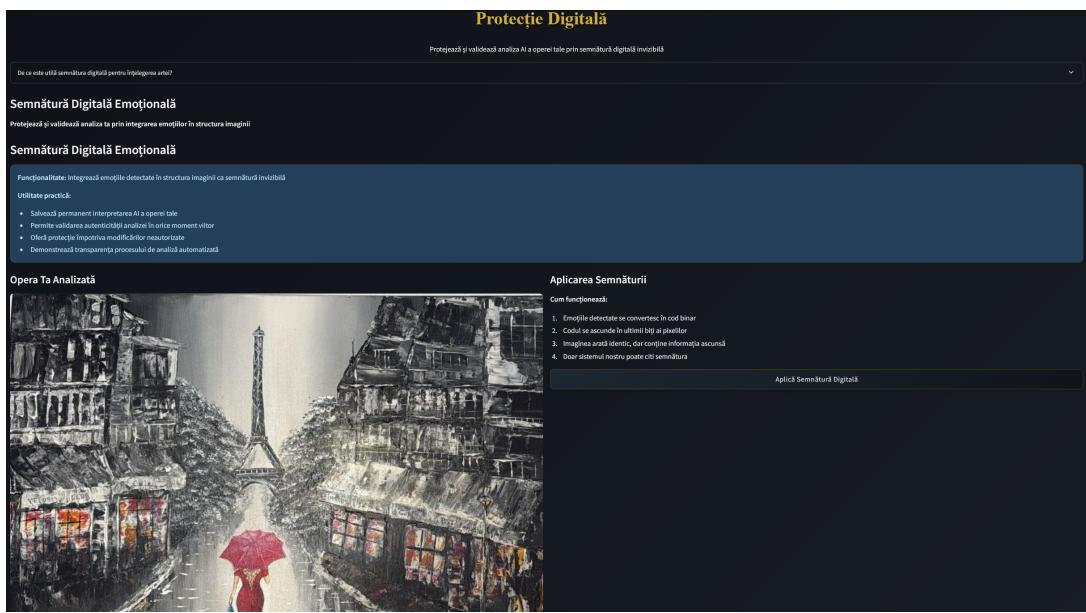


Figura 7.3: Protecție Digitală: aplicarea Semnăturii Emoționale și export imagine semnată.

7.2.2. Galerie

Afișează colecția de opere analizate cu filtre inteligente:

- **Stil & Autor, Emoție dominantă, Perioadă, Calitate**
- Detalii: scoruri, descriere narrativă, emoții predominante

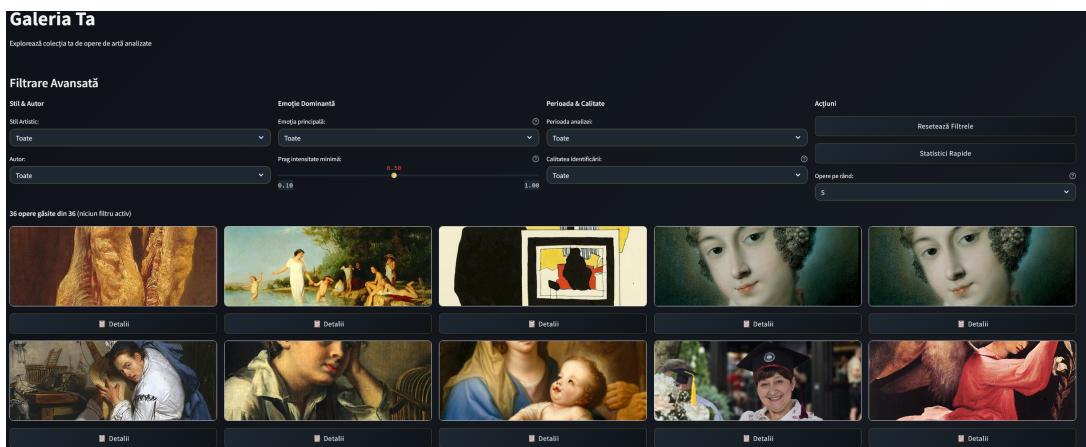


Figura 7.4: Galerie – colecția personală cu filtre după stil, autor, emoție dominantă.

7.2.3. Verificare (autenticitate semnătură)

Citește semnătura invizibilă și confirmă autenticitatea:

- Încărcați imaginea cu semnătura
- Apăsați **Începe Verificarea**
- Afișează emoții extrase + metadate (timestamp, versiune)

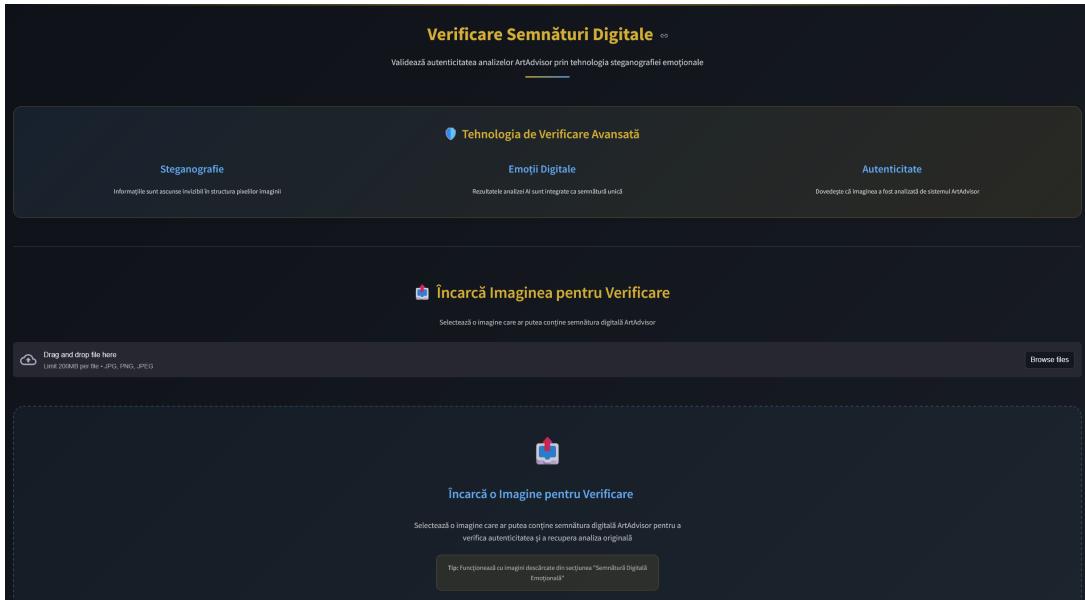


Figura 7.5: Verificare – validarea semnăturii emoționale și recuperarea emoțiilor & metadatelor.

7.2.4. Chat Artist

Interacționați cu personaje artistice (Van Gogh, Leonardo, Monet, Picasso):

- Alegeti artistul și adresați întrebare
- Sistemul utilizează contextul analizei curente (stil/emoții)



Figura 7.6: Chat Artist – dialog educațional cu mari personalități ale artei.

7.2.5. Laborator Emoțional

Permite testarea robustă a detecției emoțiilor:

- Încărcați specimen, aplicați transformări (sepia, monocrom, temperatură, saturatie, luminositate, contrast)
- Comparați vectorul emoțional înainte/după + metrii de stabilitate

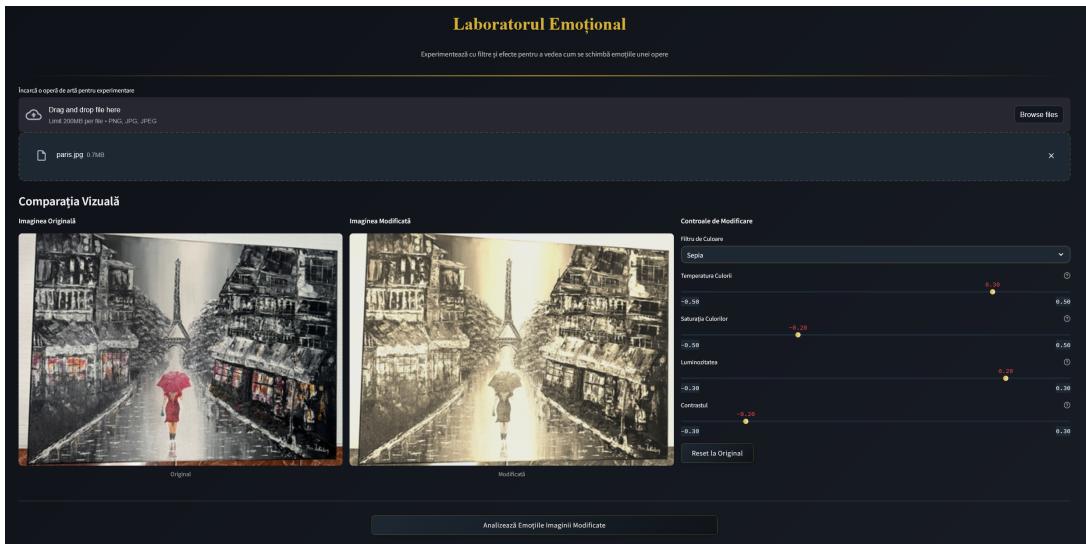


Figura 7.7: Laborator Emoțional – comparație vizuală a vectorilor emoționali (original vs. modificat).

7.3. Recomandări de bune practici

- Folosiți imagini *clare, bine iluminate, centrate, fără elemente perturbatoare*
- Pentru rezultate stabile, utilizați izolarea zonei tabloului (crop)
- Dacă GPU indisponibil, rulați pe CPU – viteza scade, dar rezultatele rămân corecte
- Exportați raportul HTML și utilizați Ctrl+P pentru PDF

7.4. Întrebări frecvente (FAQ)

- **Nu se generează audio/narațiune?** Verificați OPENAI_API_KEY
- **Modelele nu se încarcă?** Verificați fișierele .pth în models/
- **PDF nu se creează direct?** Exportați HTML și salvați ca PDF din browser

Prin acest manual, instalarea și utilizarea **ArtAdvisor** devin accesibile oricărui utilizator final. Capturile ilustrează fiecare pas – de la analiza operei, galeria personală, protecția digitală și verificarea autenticității, până la interacțiunea educațională cu marii artiști și validarea robustă a emoțiilor.

Capitolul 8. Concluzii

Acest capitol încheie lucrarea, sintetizând contribuțiile realizate, evaluând critic rezultatele și conturând direcții clare de dezvoltare. Accentul cade pe modul în care analiza emoțională asistată de inteligență artificială poate fi îmbinată cu mecanisme de verificare a autenticității pentru a crește încrederea utilizatorilor și valoarea practică a platformei **ArtAdvisor**.

8.1. Rezumatul contribuțiilor

Lucrarea îmbină dezvoltarea ML cu integrarea UI și cu un modul de securitate ușor de folosit de către utilizatorul final. Pe scurt:

1. Ingineria datelor pentru emoții

- Colectarea, filtrarea și curățarea unui set de date dedicat recunoașterii emoțiilor în picturi; eliminarea intrărilor ambiguie și standardizarea etichetelor.
- Construirea de fișiere CSV coerente și direct utilizabile pentru antrenare/validare/test.

2. Model multi-label pentru emoții (EfficientNet-B2 + ViT)

- Antrenarea unui ansamblu CNN + Transformer pentru detectia simultană a mai multor emoții.
- Calibrarea pragurilor *per clasă* pe validare pentru decizii robuste.
- Performanță finală competitivă pe test ($F1\text{-Macro} \approx 0.77$), având în vedere complexitatea subiectivă a emoțiilor.

3. Interfață modernă și explorare interactivă

- Taburi dedicate: *Analiză Operă, Galerie, Verificare, Chat Artist, Laborator Emotional*.
- Experiență fluentă: vizualizări Grad-CAM, generare narativă și *text-to-speech*, filtre inteligente în Galerie.

4. Verificare, autenticitate și robustețe

- *Semnătură Digitală Emotională* prin LSB, invizibilă, dar verificabilă.
- Evaluarea calității cu PSNR (modificări invizibile pentru utilizator atunci când PSNR este ridicat, tipic ≥ 40 dB).
- Detectarea modificărilor (tamper) și jurnal de audit; simulări adversariale exploratorii (FGSM/PGD) pentru a observa sensibilitățile.

5. Arhitectură software modulară

- Module independente, integrate coerent în orchestrarea aplicației, astfel încât verificarea să ruleze în paralel cu analiza artistică fără a afecta experiența utilizatorului.

Împărțirea contribuțiilor *Lucian*: pregătirea și curățarea datelor, ansamblul EfficientNetB2 + ViT pentru emoții (14 emoții, respectiv 8 emoții în variantele finale), antrenare și optimizare, praguri adaptive, orchestrator de predicție, integrare în UI și mecanismul de watermarking. *David Iakabos*: interfață Streamlit (taburi, UX), clasificarea stilurilor și autorilor, explicabilitate Grad-CAM, integrarea explicațiilor AI și colectarea de feedback.

8.2. Analiză critică a rezultatelor

Puncte forte

- Modelul multi-label surprinde nuanțe emoționale coexistente; calibrarea pragurilor per clasă stabilizează deciziile.
- Interfața ghidată pe taburi și integrarea *text-to-speech* cresc accesibilitatea și potențialul educațional.
- Sistemul de verificare este distinctiv: watermark-ul emoțional este invizibil, verificabil, iar PSNR confirmă că imaginea rămâne vizual neschimbată.
- Simularile adversariale au evidențiat zonele sensibile, oferind o bază factuală pentru strategii viitoare de apărare.

Limitări

- Performanța pentru emoții rare sau subtile este constrânsă de diversitatea dataset-ului.
- LSB, deși potrivit demonstrației și ușor de verificat, este vulnerabil la compresii puternice sau editări agresive.
- Rapoartele de verificare pot fi îmbogățite cu mai multe elemente vizuale orientate către non-tehnici.
- Atacurile FGSM/PGD au fost explorate demonstrativ; mecanismele de apărare necesită consolidare și testare sistematică.

8.3. Dezvoltări și îmbunătățiri ulterioare

Pe termen scurt

- Extinderea dataset-ului de emoții cu opere din mai multe culturi și perioade istorice.
- Arhitecturi îmbunătățite (de ex. EfficientNet-V2, ViT de generație nouă) și reglaj fin al pragurilor.
- UI de *Verificare* cu vizualizări mai intuitive ale semnăturii și diferențelor detectate.

Pe termen mediu

- Metode de watermarking mai robuste (rezistente la compresie și la atacuri intentionate).
- *Adversarial training* pentru creșterea rezilienței la FGSM/PGD și atacuri similare.
- Mod colaborativ în *Laborator Emotional* pentru colectarea și valorificarea feedback-ului utilizatorilor.

Pe termen lung

- Integrarea verificării într-un sistem distribuit cu audit trail securizat (ex. blockchain) pentru trasabilitate completă.
- Extensiile mobile pentru testarea autenticității în muzeu sau galerii, în condiții reale.
- Parteneriate educaționale (universități, muzeu) pentru predarea securității digitale și a AI-ului în artele vizuale.

Direcții de cercetare

- *Explainable robustness*: combinarea explicabilității vizuale (Grad-CAM) cu măsuri de reziliență la atacuri.

- Explorarea unor tactici avansate de atac/apărare (auto-attack, randomized smoothing) și evaluare standardizată.
- Analiza integrată emoții-autenticitate: cum modificările vizuale (tamper/adversarial) influențează percepția emoțională.

8.4. Concluzii finale

Lucrarea demonstrează că **analiza emoțională și verificarea autenticității** se completează natural în **ArtAdvisor**: sistemul nu doar clasifică și povestește o operă, ci și oferă garanții privind integritatea rezultatelor. Cu un F1-Macro de ordinul ~0.77 pentru recunoașterea emoțiilor și cu un modul de verificare bazat pe watermarking LSB, PSNR și teste aduersariale exploratorii, contribuția este substanțială și complementară față de componenta de stil și autor.

Prin combinarea tehniciilor moderne de AI cu mecanisme de securitate, proiectul arată că încrederea în sisteme inteligente poate fi consolidată, iar aplicațiile rezultate pot genera impact real în educație, cercetare și conservarea digitală a artei. În această viziune, inteligența artificială devine nu doar un instrument de clasificare, ci un *partener de validare și protecție*, deschizând direcții noi pentru aplicații culturale și academice.

Anexa A. Secțiuni relevante din cod

```
/** Maps are easy to use in Scala. */
object Maps {
    val colors = Map("red" -> 0xFF0000,
                     "turquoise" -> 0x00FFFF,
                     "black" -> 0x000000,
                     "orange" -> 0xFF8040,
                     "brown" -> 0x804000)
    def main(args: Array[String]) {
        for (name <- args) println(
            colors.get(name) match {
                case Some(code) =>
                    name + " has code: " + code
                case None =>
                    "Unknown color: " + name
            }
        )
    }
}
```

Anexa B. Alte informații relevante (demonstrații etc.)

Se va elimina dacă nu există

Anexa C. Lucrări publicate (dacă există)

Se va elimina dacă nu există